Fachhochschule Nordwestschweiz
Hochschule für Technik

Application Performance Management

Einführung Performance-Analyse

Michael Faes

Persönliches

Michael Faes
michael.faes@fhnw.ch

Wohnort: Aesch BL

Dazwischen: Reisen, Fotografie, Beach Volley, Kino, Jungschar

Bachelor & Master ETH Zürich

Praktikum Canoo AG

Doktorat ETH

Lehrdiplom Sek II

Dozent FHNW

- EIPR, OOP1, OOP2
- Web Engineering
- Application Performance Management
- *Didactic Track*

dieses Modul

“Make it Work, Make it Right, *Make it Fast*.”

— Kent Beck, Erfinder von Extreme Programming

In dieser Reihenfolge!

> “Premature optimization is the root of all evil in programming.”
>
> — Donald Knuth

Performance ist trotzdem oft wichtig! Die Kunst ist es, die grossen Gewinne zu identifizieren und einzuholen.

Es geht um Performance

Performance **messen**

Performance-**Probleme identifizieren**

Performance **charakterisieren**

Performance **vorhersagen**

Performance **vergleichen**

Performance **«optimieren»**

Performance **visualisieren**

Demo: Performance messen

Performance-Messungen mit *aussagekräftigen* Resultaten sind alles andere als trivial.

Demo: Ausführungszeit einer Methode in Java messen

Probleme

- Variation
- Genauigkeit
- Warmup
- Interaktion mit anderem Code

```java
public class Factorization {

    private static final long NUMBER = 64273117L;

    public static void main(String[] args) {
        var start = System.currentTimeMillis();

        var factors = factorize(NUMBER);
        System.out.println(NUMBER + ": " + factors);

        double time = (System.currentTimeMillis() - start);
        System.out.printf("%.2f ms\n\n", time);
    }

    private static List<Long> factorize(long num) {
        var factors = new ArrayList<Long>();
        long factor = 2;
        while (factor <= num) {
            while (num % factor == 0) {
                factors.add(factor);
                num /= factor;
                if (num == 1) {
                    return factors;
                }
            }
            factor++;
        }
        throw new AssertionError();
```

Wichtigste Lernziele

- Sie können *Techniken*, *Metriken* und *Workloads* zum Evaluieren der Performance eines Systems angemessen auswählen.
- Sie können *Performance-Messungen* korrekt durchführen.
- Sie kennen verschiedene Techniken zur *Performance-Optimierung* einer Applikation und können diese erfolgreich einsetzen.
- Sie können Daten aus Performance-Messungen durch *Visualisierung* und mittels *statistischer Methoden* auswerten.
- Sie kennen die Techniken *JIT-Kompilierung*, *Garbage Collection* und *Caching* und können deren Einfluss auf die Performance einschätzen.
- Sie kennen die Grundlagen von *Load Balancing*, *Clustering* und *Autoscaling* und können diese Techniken einsetzen, um eine Applikation skalierbar und hochverfügbar zu machen.

Modulübersicht

W	Datum	Inhalte
1	20.02.	Einführung Performance-Analyse & Parallelisierung
2	27.02.	Performance-Optimierung & Profiling
3	06.03.	Experiment-Design & Benchmarking
4	13.03.	Datenauswertung & Präsentation
5	20.03.	I/O & Buffering
6	27.03.	Skalierung & Load Balancing *Prüfungsvorbereitung*
7	03.04.	***Assessment 1: W1 – W5*** Clustering & High Availability
	10.04.	*Osterferien*
8	17.04.	Garbage Collection
9	24.04.	Just-in-Time-Kompilierung
10	01.05.	*Tag der Arbeit*
	08.05.	*Projektwoche*
11	15.05.	Performance Testing im Web
12	22.05.	Caching
13	29.05.	*Pfingstmontag*
14	05.06.	Performance Management & Autoscaling *Prüfungsvorbereitung*
15	12.06.	***Assessment 2: W6 – W14***

Wochen 1 – 5
Grundlagen

Spezialthemen
(Gastdozent: Dr. Majó)

Wochen 6 – 14
Web-Apps & Cloud

Leistungsbeurteilung

W	Datum	Inhalte
1	20.02.	Einführung Performance-Analyse & Parallelisierung
2	27.02.	Performance-Optimierung & Profiling
3	06.03.	Experiment-Design & Benchmarking
4	13.03.	Datenauswertung & Präsentation
5	20.03.	I/O & Buffering
6	27.03.	Skalierung & Load Balancing *Prüfungsvorbereitung*
7	03.04.	***Assessment 1: W1 – W5*** Clustering & High Availability
	10.04.	*Osterferien*
8	17.04.	Garbage Collection
9	24.04.	Just-in-Time-Kompilierung
10	01.05.	*Tag der Arbeit*
	08.05.	*Projektwoche*
11	15.05.	Performance Testing im Web
12	22.05.	Caching
13	29.05.	*Pfingstmontag*
14	05.06.	Performance Management & Autoscaling *Prüfungsvorbereitung*
15	12.06.	***Assessment 2: W6 – W14***

Leistungsbeurteilung

2 Assessments

60 min schriftlich

Hilfsmittel:

- je eine A4-Seite Zusammenfassung

Lernmaterial

Folien, Scripts & Übungen: https://github.com/apm-fhnw/apm-fs23

Bücher: Kurs basiert auf verschiedenen Büchern. Keine Pflichtlektüre, aber für Interessierte vielleicht nützlich:

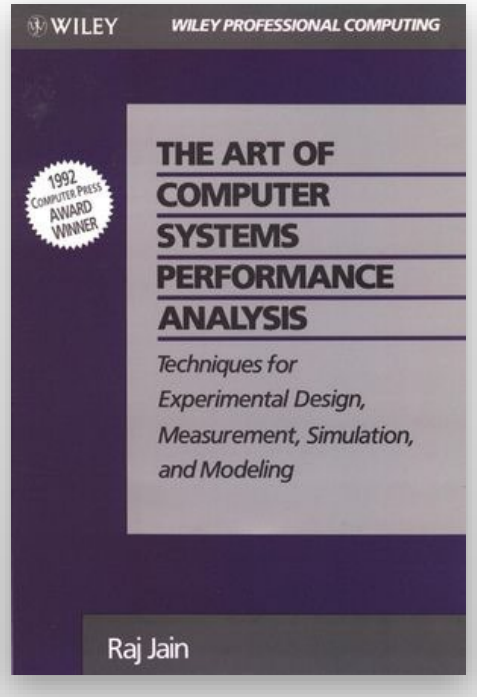

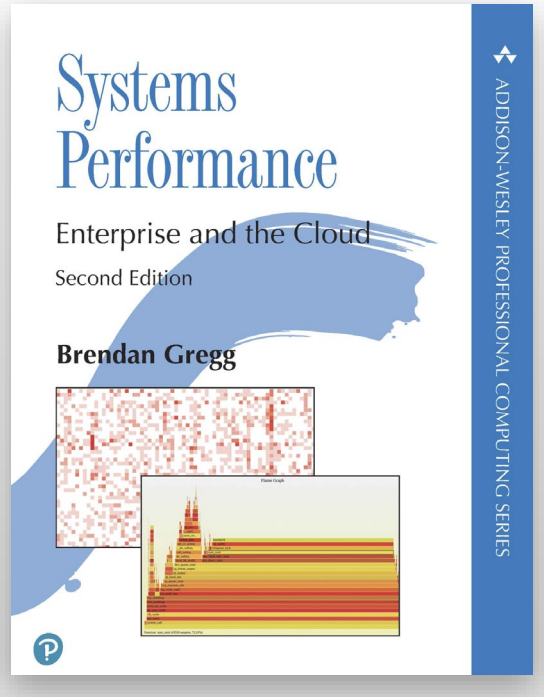

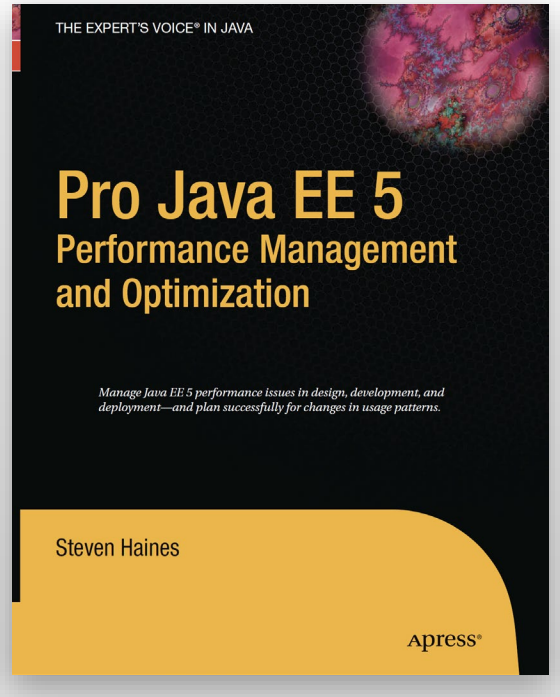

Übersicht Woche 1

1. Modulübersicht & Administratives
2. Einführung Performance-Analyse
3. Evaluationstechniken & Performance-Metriken
4. Parallelisierung mit Java
5. Übung: *Doc Finder*

Einführung Performance-Analyse

Performance ist schwierig

Performance ist komplex. Siehe Demo…

Grund: Performance-Optimierungen sind nicht meist nicht «uniform».

- Oft wird für ***typische Workloads*** optimiert, da *insgesamt effizienter*

Beispiel: *Instruction Pipelining*: erhöht CPU-Leistung in ***vielen*** Fällen

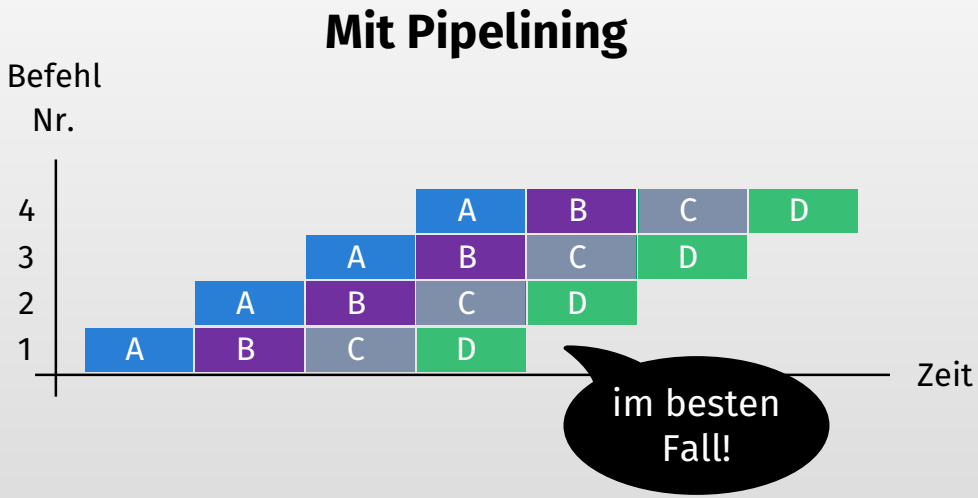

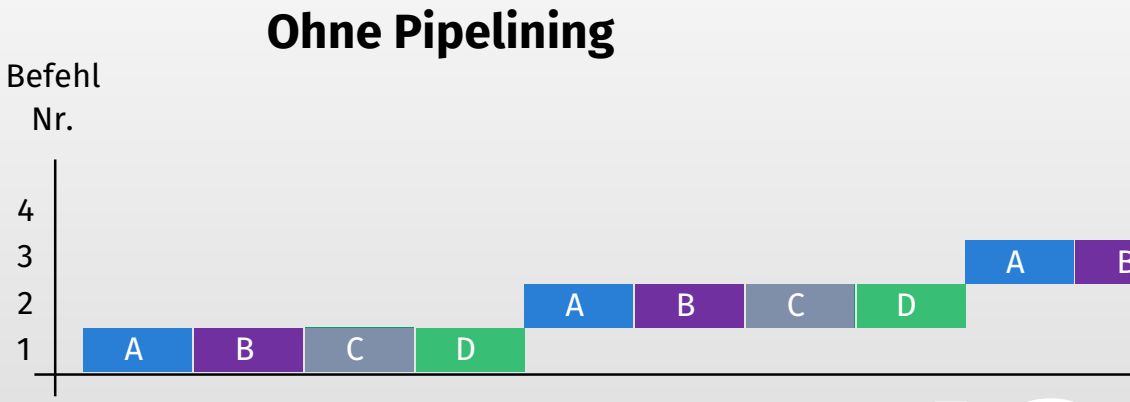

Weitere Beispiele

- *Branch Prediction*: Um Pipelining effizienter zu machen, wird verhalten von Sprung-Instruktionen ***vorhergesagt***.

  Funktioniert in bis zu 98% der Fällen. Aber wenn nicht...

- *JIT-Kompilierung*: Nur Code, der ***oft genug*** ausgeführt wurde, wird kompiliert und optimiert. Wird für zahlreiche Sprachen gemacht:

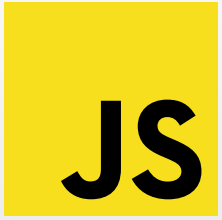

- *Caching*: Sparen von mehrmaligen Berechnungen oder Abrufen durch Zwischenspeichern. Ebenfalls durch ***Vorhersage***.

Performance hängt von unglaublich vielen Faktoren ab.

Beispiel 1: Paper *Producing wrong data without doing anything obviously wrong!*

- Anzahl/Grösse der *Umgebungsvariablen* führt zu unterschiedlichen Resultaten beim Vergleichen von Compiler-Optimierungen

Beispiel 2: *Shouting in the datacenter*

https://youtu.be/tDacjrSCeq4

Auswertung von Performance-Daten ebenfalls nicht trivial.

Beispiel: *Ratio Game*. Leistung eines Systems wurde in Transaktionen pro Sekunde (Durchsatz) gemessen:

System	Workload 1	Workload 2
A	20	10
B	10	20

Drei Möglichkeiten, die Systeme zu vergleichen:

Sys	Workload 1	Workload 2	**Ø**
A	20	10	**15**
B	10	20	**15**

Durchschnittlicher Durchsatz

Sys	Workload 1	Workload 2	**Ø**
A	200%	50%	**125%**
B	100%	100%	**100%**

Durchsatz relativ zu System B

Sys	Workload 1	Workload 2	**Ø**
A	100%	100%	**100%**
B	50%	200%	**125%**

Durchsatz relativ zu System A

Performance-Analyse ist...

... ein Handwerk

Erfordert viel theoretisches und praktisches Wissen und systematische Vorgehensweisen

... eine Kunst

Viele Experten haben eigene Methodologien und Herangehensweisen. Werden einige davon kennenlernen.

...eine Wissenschaft

Wissenschaftler «entdecken» immer wieder Dinge über Performance (obwohl Systeme ja von Menschen gebaut sind!)

- Resultate werden an Konferenzen veröffentlicht, z. B. *SIGMETRICS*

Evaluationstechniken & Metriken

Evaluationstechniken

Performance kann grundsätzlich auf drei Arten untersucht werden.

1. ***Analytische Modellierung***

   System wird vereinfacht, mathematisch beschrieben & untersucht.

   Beispiele:

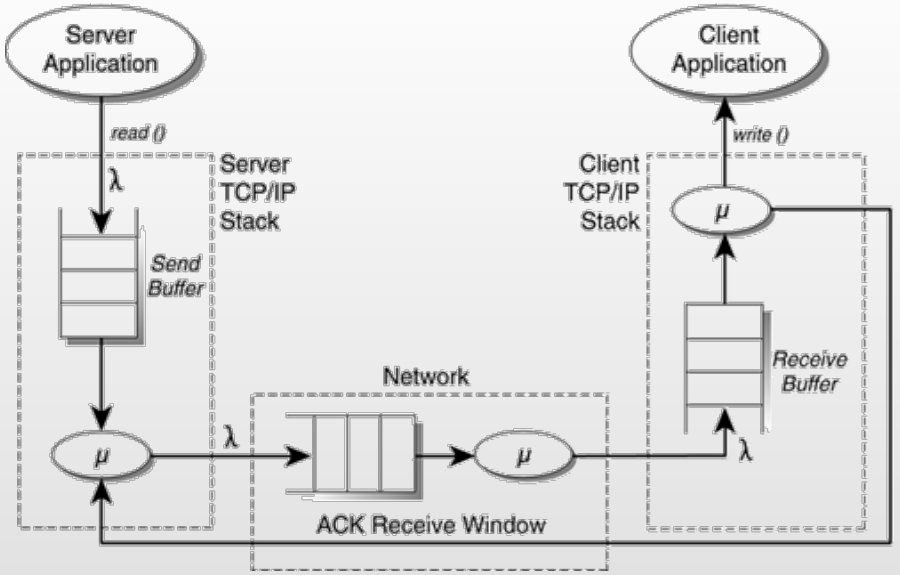

Warteschlangentheorie

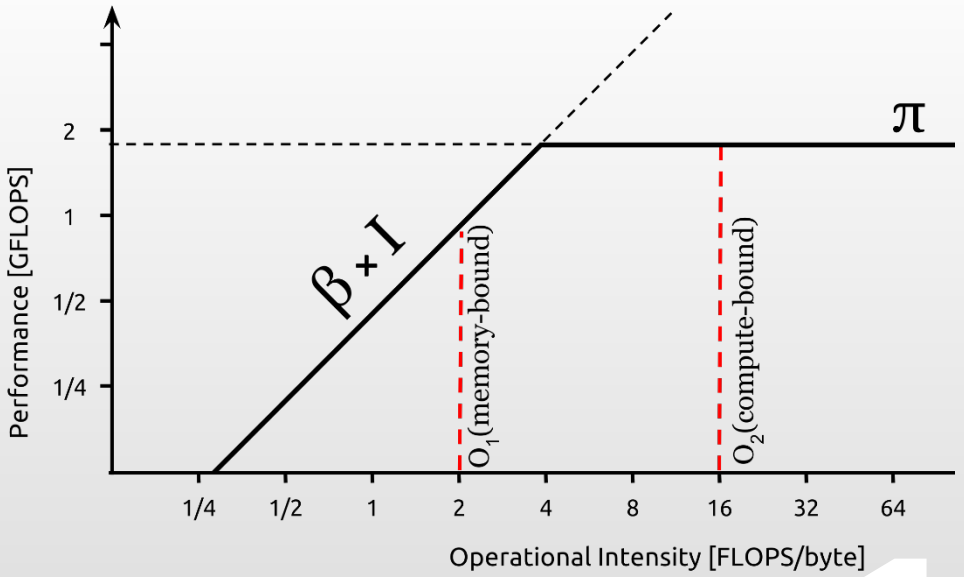

Roofline model

2. *Simulation*

Erlaubt mehr Details als analytische Modelle, aber liefert keine Zusammenhänge.

3. *Messung*

«The real thing»; setzt funktionierendes System/Prototyp voraus. Resultate sind immer *Realitäts-nah*, aber trotzdem *nicht unbedingt aussagekräftig*.

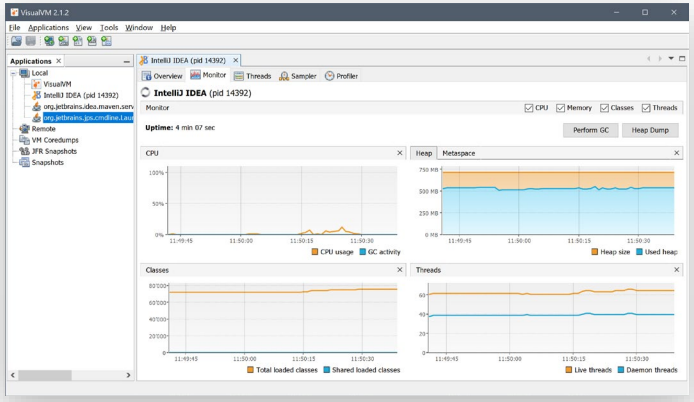

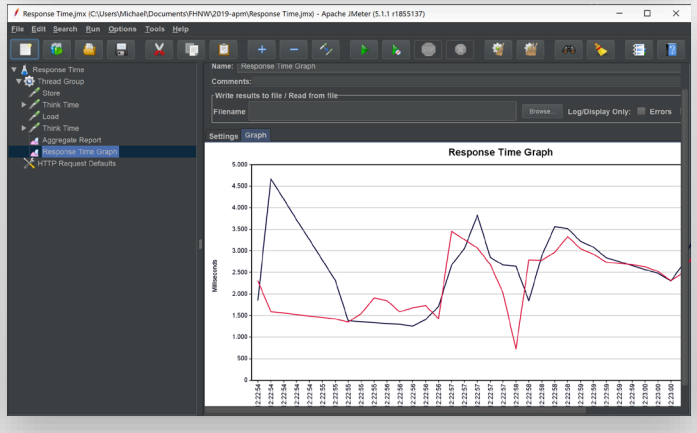

Fundamentales Problem: Man misst immer ***in einer bestimmten Situation***.

In APM: Vor allem Messung. Aber Modelle (oder Simulationen) sind nützlich, um Resultate einzuordnen/zu validieren.

Performance-Metriken

Um Performance zu *quantifizieren* (messen, vergleichen, usw.) braucht es *Metriken*. Auswahl von Metriken hat grossen Einfluss auf Resultate.

Grundlage: Grobmodell eines *Systems*. System hat mehrere *Dienste*, welche *Anfragen* beantworten. Verschiedene *Ergebnisse* möglich:

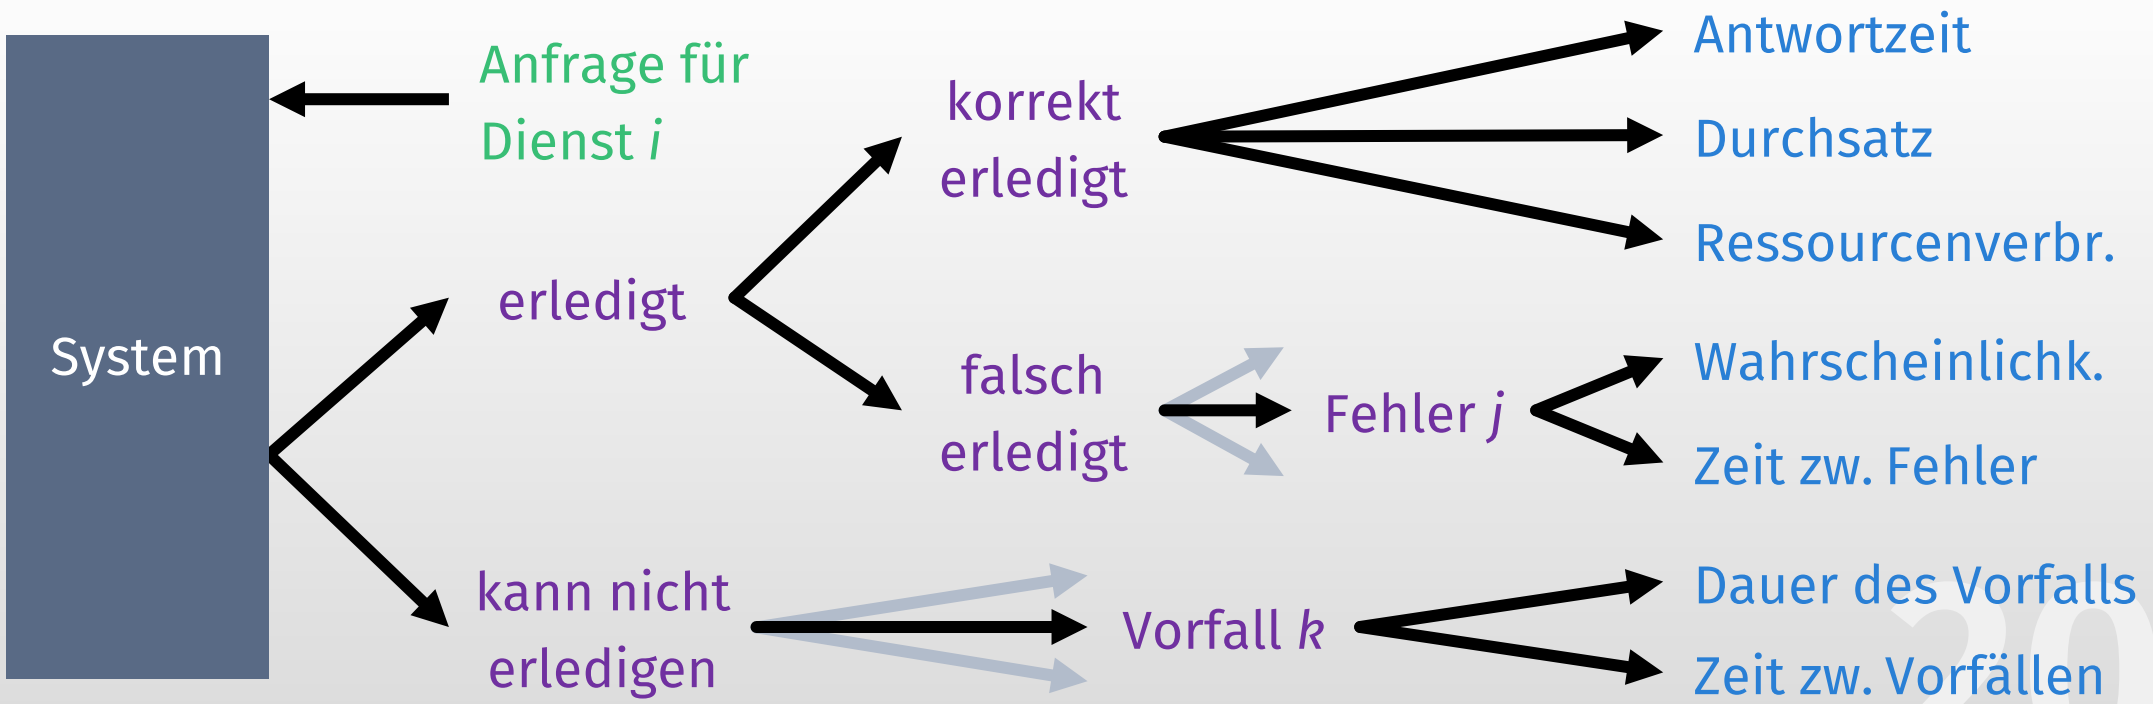

Beispiele für Systeme und Dienste:

Web-Applikation

Dienste könnten Features der App sein, z. B. Erstellen eines neuen Posts, Suchen nach Posts, usw.

REST-Service

Dienste sind die einzelnen Endpunkte

Datenbanksystem

Dienste könnten verschiedene Arten von Anfragen sein

CPU

Mögliche Definitionen von Diensten:

- Ausführen von einzelnen Instruktionen
- Ausführen von verschiedenen «*Kernels*»
- Ausführen einer kompletten Applikation

Für jeden Dienst *i*, für jeden Fehler *j* und für jeden Vorfall *k* gibt es mehrere Metriken!

Grobe Unterteilung: *Geschwindigkeit*, *Zuverlässigkeit*, *Verfügbarkeit*

- Entsprechen den drei Arten von Ergebnissen

Zudem: Metrik ist nicht *eine* Zahl, sondern *Verteilung*.

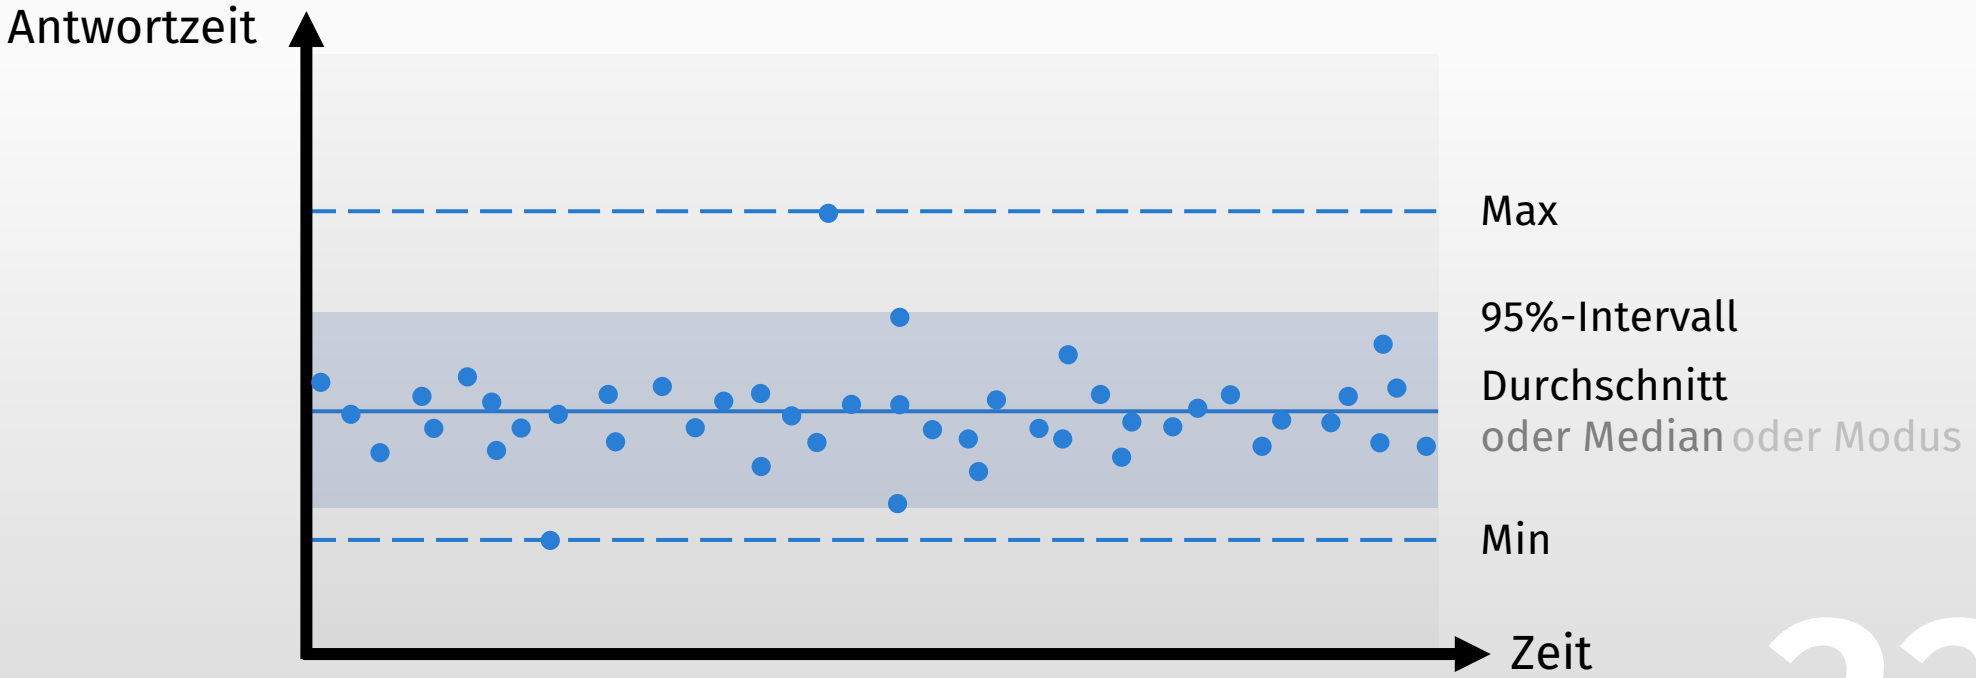

Häufig verwendete Performance-Metriken

Antwortzeit / Latenz (response time / latency)

Zeitintervall zwischen Anfrage und Antwort

Vereinfachung! Anfrage und Antwort sind nicht ein einziger Zeitpunkt:

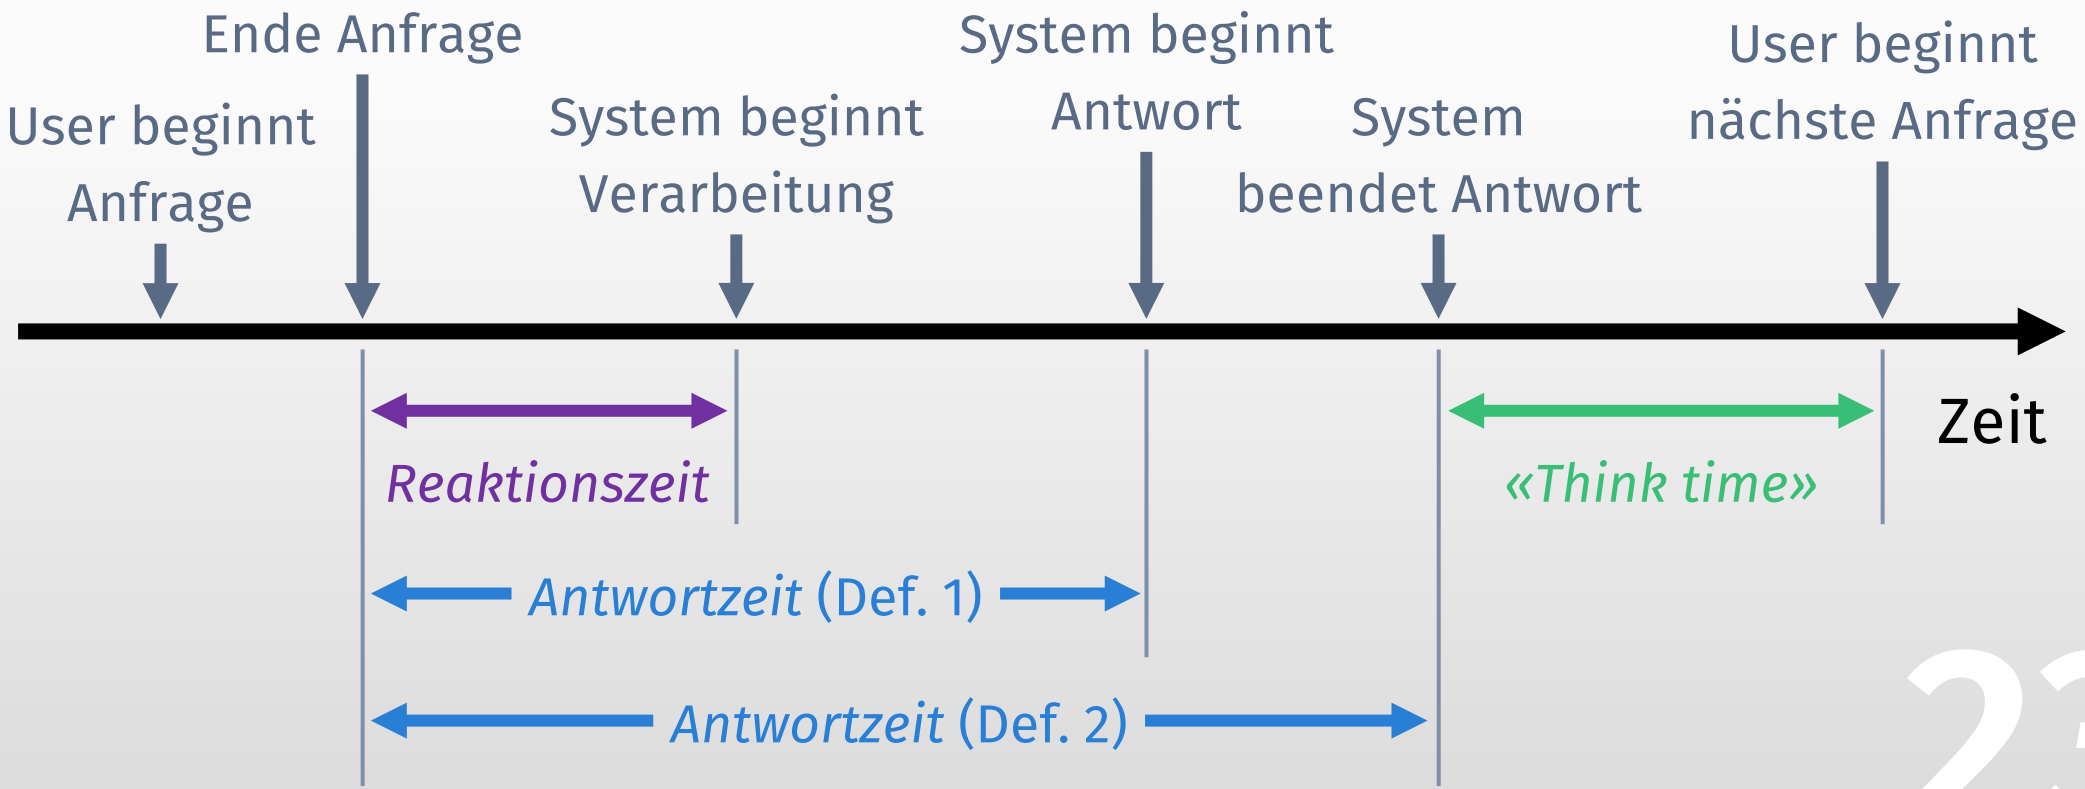

Zeitmassstäbe in Computersystemen:

Event	Scaled
1 CPU cycle	1 s
Level 1 cache access	3 s
Level 2 cache access	
Level 3 cache access	
Main memory access (DRAM, from CPU)	
Solid-state disk I/O (flash memory)	
Rotational disk I/O	
Internet: San Francisco to New York	
Internet: San Francisco to United Kingdom	
Lightweight hardware virtualization boot	
Internet: San Francisco to Australia	
OS virtualization system boot	
TCP timer-based retransmit	
SCSI command time-out	
Hardware (HW) virtualization system boot	
Physical system reboot	

Quelle: Gregg (2020)

Zeitmassstäbe in Computersystemen:

Event	Latency	Scaled
1 CPU cycle	0.3 ns	1 s
Level 1 cache access	0.9 ns	3 s
Level 2 cache access	3 ns	10 s
Level 3 cache access	10 ns	33 s
Main memory access (DRAM, from CPU)	100 ns	6 min
Solid-state disk I/O (flash memory)	10–100 µs	9–90 hours
Rotational disk I/O	1–10 ms	1–12 months
Internet: San Francisco to New York	40 ms	4 years
Internet: San Francisco to United Kingdom	81 ms	8 years
Lightweight hardware virtualization boot	100 ms	11 years
Internet: San Francisco to Australia	183 ms	19 years
OS virtualization system boot	< 1 s	105 years
TCP timer-based retransmit	1–3 s	105–317 years
SCSI command time-out	30 s	3 millennia
Hardware (HW) virtualization system boot	40 s	4 millennia
Physical system reboot	5 m	32 millennia

Quelle: Gregg (2020)

Durchsatz (throughput): *Erledigte Anfragen pro Zeiteinheit*

Beispiele

- MIPS (*mio instructions per second*)
- GFLOPS
- Transaktionen pro Sekunde

Durchsatz wird normalerweise *grösser, je höher die Last*. Aber nur, solange System noch nicht voll ausgelastet ist!

Zusammenhang mit Antwortzeit:

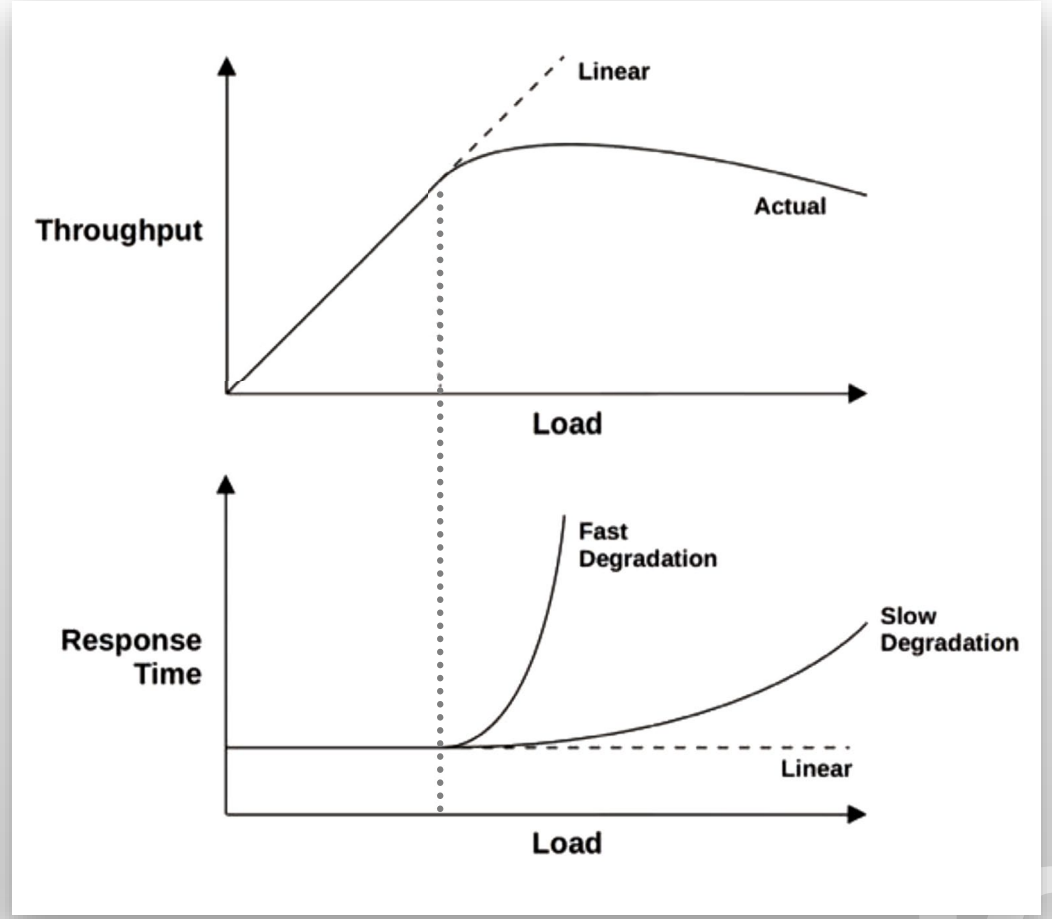

Quelle: Gregg (2020)

Maximaler Durchsatz unter idealen Bedingungen entspricht *nominaler Kapazität* eines Systems

- Wird oft erst erreicht, wenn Antwortzeit inakzeptabel gross ist

Interessanter ist oft *brauchbare Kapazität*: maximal möglicher Durchsatz *ohne vordefinierte Antwortzeit zu überschreiten*.

Effizienz: *Verhältnis zwischen brauchbarer und nominaler Kapazität*

Beispiel LAN

- nominale Kapazität (*Bandbreite*): 1 Gbit/s
- brauchbare (erreichbare) Kapazität: 800 Mbit/s
- Effizienz: 80%

Speedup

Spezifisch für *parallele Verarbeitung*: *Verhältnis von Durchsatz mit n Prozessoren zu Durchsatz mit 1 Prozessor.*

Weiteres Beispiel für Effizienz:

$$\text{Effizienz} = \frac{\text{Speedup}}{n}$$

Typisches Verhalten:

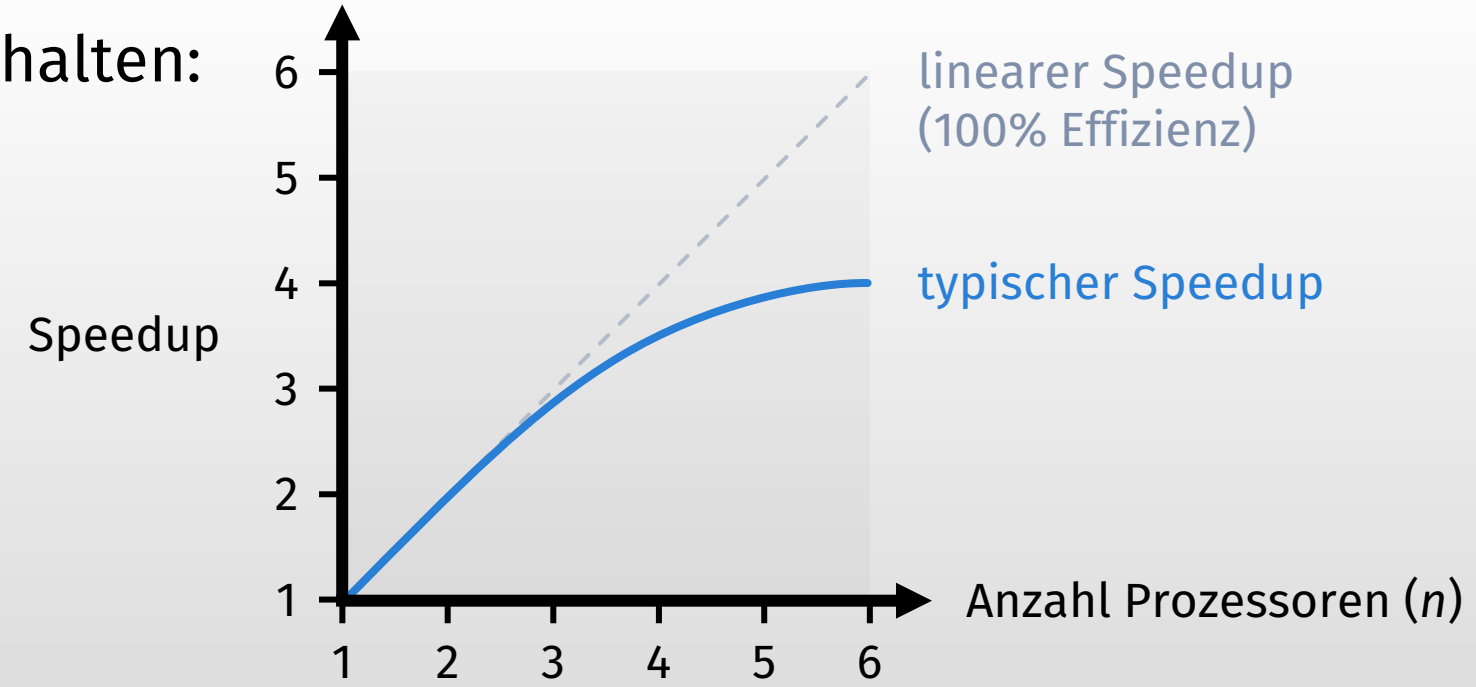

Zu folgenden Metriken mehr in späteren Wochen:

Auslastung (utilization)
Verhältnis zwischen Zeit, in der Ressource verwendet wird, und Gesamtzeit (...)

Sättigung (saturation)
Ausmass von «Überbelastung», d. h. Arbeit, die wegen Vollauslastung nicht sofort erledigt werden kann

Zuverlässigkeit (reliability)
Wahrscheinlichkeit von fehlerhaften Antworten, oder durchschnittliche Zeit zwischen solchen

Verfügbarkeit (availability)
Anteil der Zeit, während der das System Anfragen beantwortet, z. B. 99%

Nutzenklassifikation von Metriken

Jede Metrik gehört zu einer von drei Klassen:

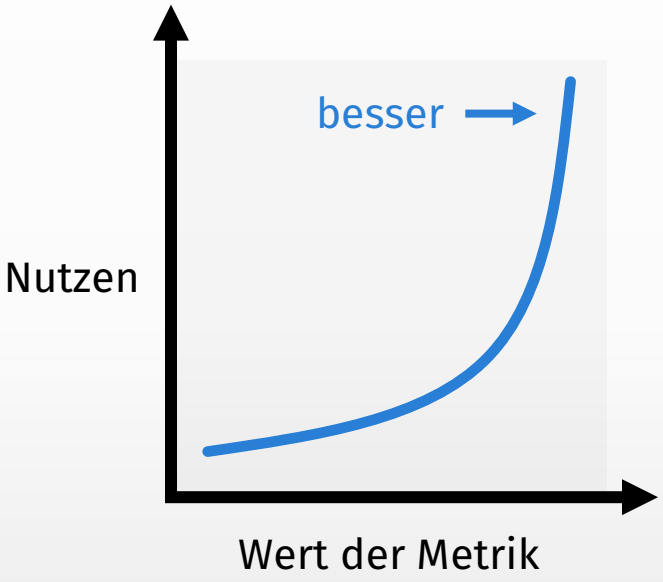

«höher ist besser»

Beispiel: Durchsatz

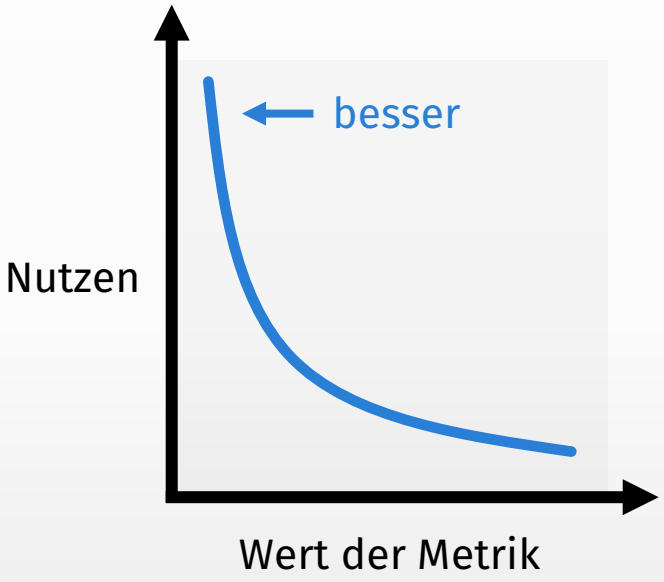

«tiefer ist besser»

Beispiel: Antwortzeit

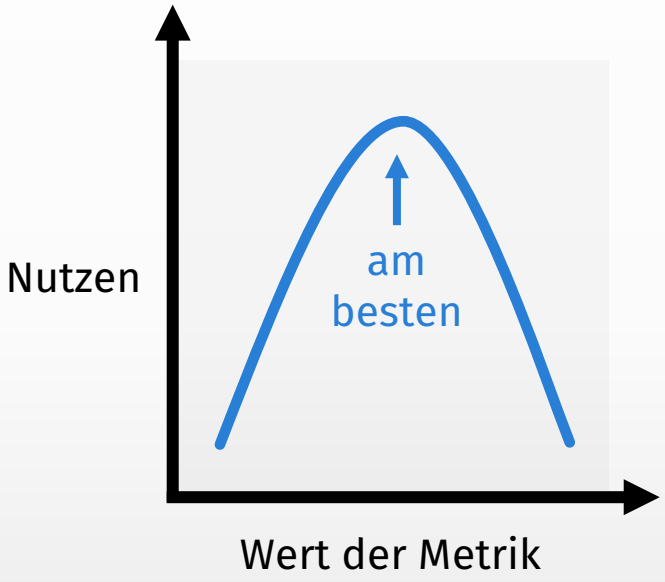

«bestimmter Wert ist am besten»

Beispiel: Auslastung

Parallelisierung mit Java

Ein Crashkurs

Disclaimer

Vorsicht: Parallele Programme schreiben ist nicht etwas, das man in *einer Woche* lernt!

Falls Sie keine Erfahrung mit Concurrency und paralleler Programmierung haben, probieren Sie das nicht in «wichtigem» Code…

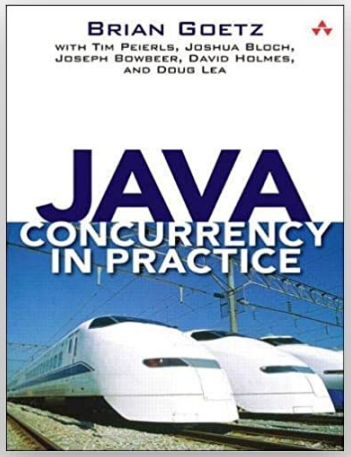

Weitere Ressourcen:

- Modul *Concurrent Programming*
- Buch *Java Concurrency in Practice* von Brian Goetz

Die Thread-Klasse

```
public class HelloAndGoodbye {

   public static void main(String[] args) {
      Runnable hello = () -> {
         for (int i = 1; i <= 1000; i++) {
            System.out.println("Hello " + i);
         }
      };
      Runnable goodbye = () -> {
         for (int i = 1; i <= 1000; i++) {
            System.out.println("Goodbye " + i);
         }
      };
      var t1 = new Thread(hello);
      var t2 = new Thread(goodbye);
      t1.start();
      t2.start();
   }
}
```

Reihenfolge nicht immer gleich

```
Goodbye 1
Goodbye 2
Hello 1
Hello 2
⋮
Hello 32
Hello 33
Goodbye 3
Goodbye 4
⋮
Goodbye 26
Goodbye 27
Hello 34
Hello 35
⋮
Hello 68
Hello 69
Goodbye 28
Goodbye 29
Hello 70
Hello 71
Goodbye 30
Goodbye 31
```

Parallele Verarbeitung

Mehrere Threads können ***gleichzeitig*** Code ausführen, falls mehrere CPUs (bzw. CPU-Cores) vorhanden sind.

Beispiel: Zerlegen von Zahlen in Primfaktoren, z. B. 60 = 2 × 2 × 3 × 5

```
var start = System.currentTimeMillis();

for (var num : NUMBERS) {
    var factors = factorize(num);
    System.out.println(num + ": " + factors);
}

var time = (System.currentTimeMillis() - start) / 1000.0;
System.out.printf("\n%.1f seconds\n", time);
```

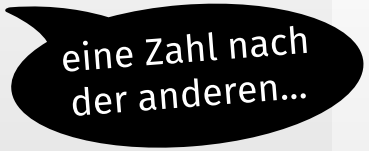


```
...
6198491414655: [3, 3, 5, 19, 61, 118847501]
6689508176080: [2, 2, 2, 2, 5, 769, 108737129]

10.6 seconds
```

Besser: Aufgabe aufteilen. Jede Zahl kann *unabhängig von anderen* zerlegt werden. Mehrere Threads, jeder übernimmt ein paar Zahlen.

```
var threads = new ArrayList<Thread>();
var numsPerThread = NUMBERS.size() / NUM_THREADS;
for (var i = 0; i < NUMBERS.size(); i += numsPerThread) {

   var partition = NUMBERS.subList(i, i + numsPerThread);

   var t = new Thread(() -> {
      for (var num : partition) {
         var factors = factorize(num);
         System.out.println(num + ": " + factors);
      }
   });
   t.start();
   threads.add(t);
}

for (var t : threads) {
   t.join();
}
```

aufteilen…

und in mehreren Threads ausführen

andere Reihenfolge…

```
...
2747561899166: [2, 7, 1667, 117729107]
8653241755480: [2, 2, 2, 5, 7, 7, 43, 102672541]

1.5 seconds
```

aber viel schneller!

Muss das so kompliziert sein?

Nein.

```
NUMBERS.parallelStream().forEach(num -> {
    var factors = factorize(num);
    System.out.println(num + ": " + factors);
});
```

```
...
2717339902199: [13, 1873, 111599651]
6428733687135: [3, 3, 5, 1451, 98456753]

1.5 seconds
```

`parallelStream()` teilt Daten in mehrere Unter-Streams auf, die unabhängig voneinander verarbeitet werden.

`parallelStream()` ist einfach zu verwenden, aber bietet keine Kontrolle über Performance.

Alternative: *Thread-Pool*, mittels `ExecutorService`-Interface

```
var executor = Executors.newFixedThreadPool(NUM_THREADS);
for (var num : NUMBERS) {
    executor.submit(() -> {
        var factors = factorize(num);
        System.out.println(num + ": " + factors);
    });
}
```

Warten bis alle Tasks abgearbeitet wurden (einfachster Weg):

```
executor.shutdown();
executor.awaitTermination(1, TimeUnit.HOURS);
```

Fragen?

Anhang

Probleme mit Multithreading

Multithreading-Modell

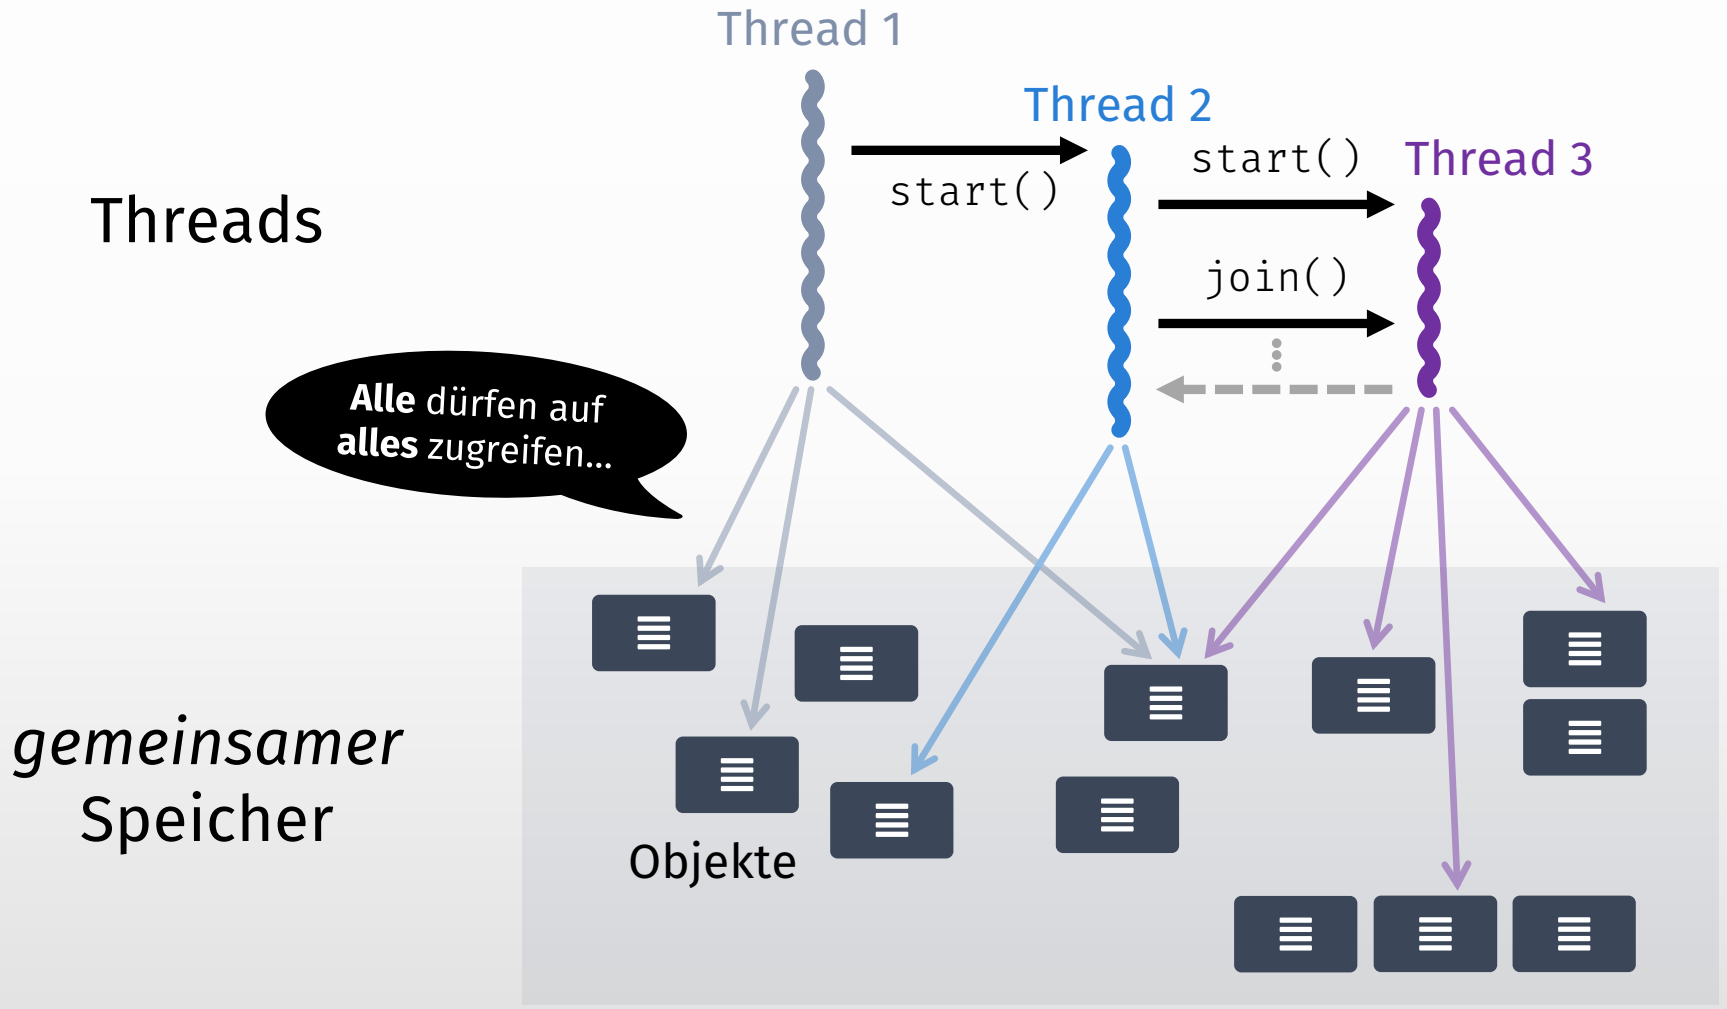

Problem 1: Sichtbarkeit

gemeinsamer Zustand: **boolean**-Attribut

```
private boolean done = false;

private void run() throws InterruptedException {
   var reader = new Thread(() -> {
      while (!done) {
         // nothing to do here...
      }
      System.out.println("reader is done");
   });
   reader.start();

   // wait a little...
   Thread.sleep(1000);

   done = true;
   System.out.println("writer is done");
}
```

pausiert aktuellen Thread (ms)

Erwartetes Verhalten:

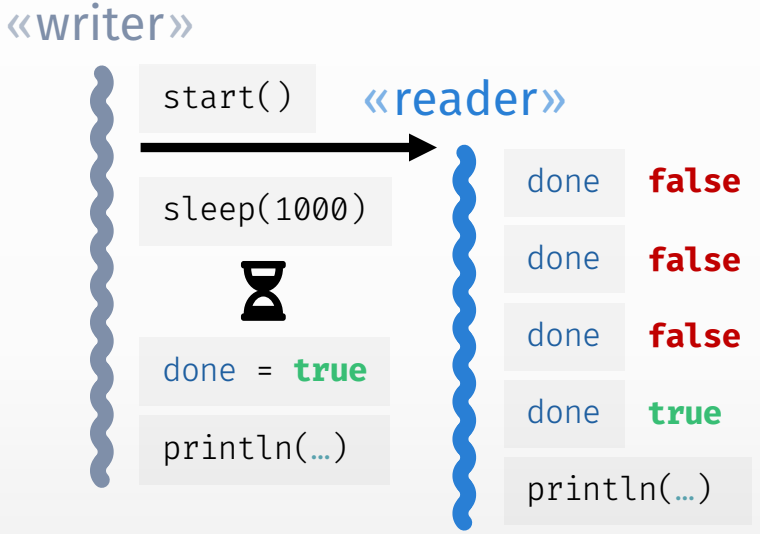

1s Pause

```
writer is done
reader is done
```

(oder umgekehrt)

Beobachtetes Verhalten:

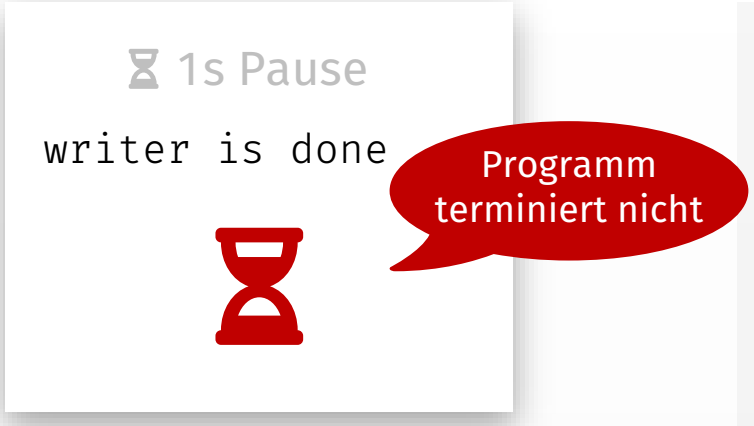


```
private boolean done = false;

private void run() throws … {
  var reader = new Thread(() -> {
    while (!done) {}
    …println("reader is done");
  });
  reader.start();

  Thread.sleep(1000);
  done = true;
  …println("writer is done");
}
```

Wie ist so etwas möglich?

Antwort: *Java gibt grundsätzlich keine Garantie, dass Änderungen von einem Thread in anderen Threads jemals sichtbar werden.*

Noch schlimmer: Kleine Änderung am Programm ändert das Verhalten.

```
private boolean done = false;

private void run() throws InterruptedException {
   var reader = new Thread(() -> {
      while (!done) {
         System.out.println("still waiting");
      }
      System.out.println("reader is done");
   });
   reader.start();

   // wait a little...
   Thread.sleep(1000);

   done = true;
   System.out.println("writer is done");
}
```

```
still waiting
still waiting
⋮
still waiting
still waiting
writer is done
reader is done
```

Jetzt terminiert das Programm (bei mir)

Sichtbarkeit: Garantien

Java gibt einige *spezifische* Garantien über Sichtbarkeit:

1. Der Wert in einer `final`-Variable ist sichtbar, nachdem das Objekt erstellt wurde.
2. Der Wert in einer `static`-Variable ist sichtbar, nachdem der `static`-Block der Klasse ausgeführt wurde.
3. Änderung vor dem Freigeben eines *Locks* ist sichtbar für alle Threads, die das *Lock* danach erwerben.
4. Änderungen an einer `volatile`-Variable sind *immer sichtbar*.

Programm verhält sich **garantiert** korrekt, wenn wir gemeinsame Variable als **`volatile`** deklarieren, …

```
private volatile boolean done = false;

private void run() throws InterruptedException {
   var reader = new Thread(() -> {
      while (!done) {}
      System.out.println("reader is done");
   });
   reader.start();

   Thread.sleep(1000);
   done = true;
   System.out.println("writer is done");
}
```

⏳ 1s Pause

```
writer is done
reader is done
```

… das ist aber nicht unbedingt empfohlen (siehe später).

Problem 2: Reihenfolge von Operationen

```
private volatile int value = 0;

private void run() {
    Runnable incrementer = () -> {
        for (int i = 0; i < 10000; i++) {
            value++;
        }
    };

    var t1 = new Thread(incrementer);
    var t2 = new Thread(incrementer);
    t1.start();
    t2.start();

    t1.join();
    t2.join();
    System.out.println(value);
}
```

Erwartetes Verhalten:

```
20000
```

Beobachtetes Verhalten:

```
14868
```

oder

```
16864
```

oder

```
17221
```

oder

```
12943
```

Wie ist jetzt das möglich? Haben doch extra **`volatile`** verwendet!

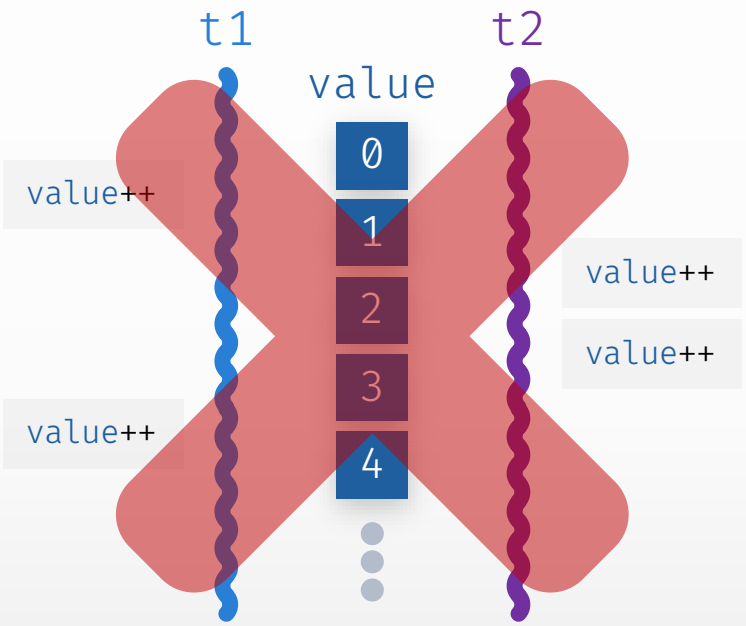

Sollte doch gehen,
Reihenfolge ist egal!

Problem:

`value++;` ist in Wirklichkeit:

```
t = value;
t++;
value = t;
```

temporäre Kopie

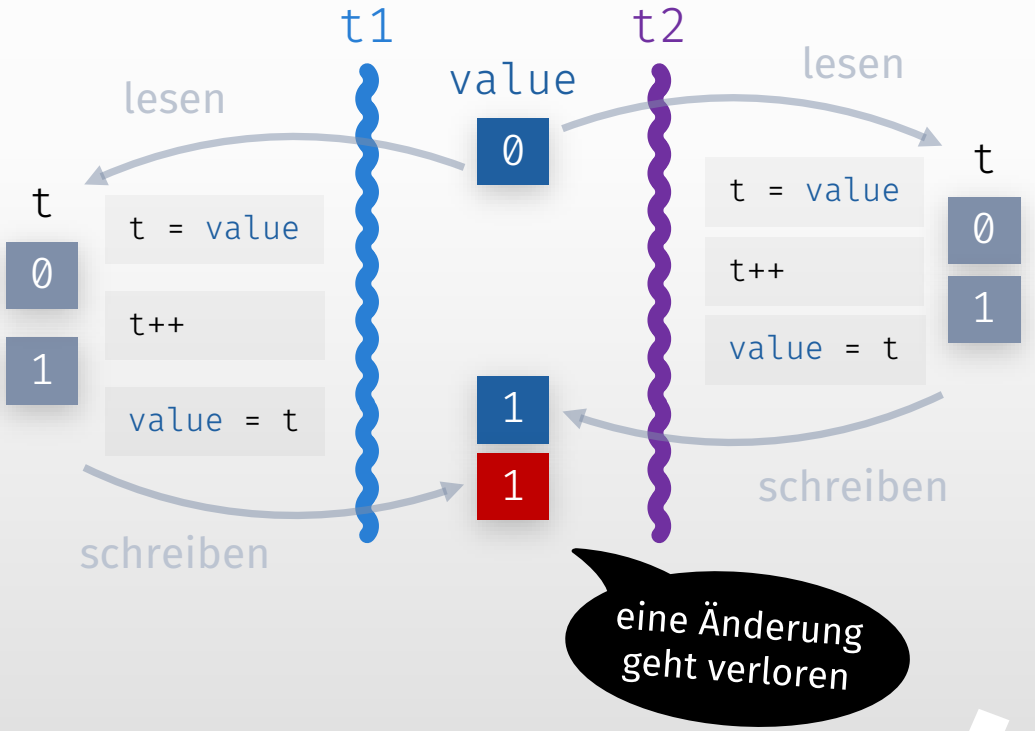

Atomare Operationen

Um Problem zu lösen, müssen wir Überlappung von Operationen verhindern. Eine Möglichkeit: ***atomare Operationen***.

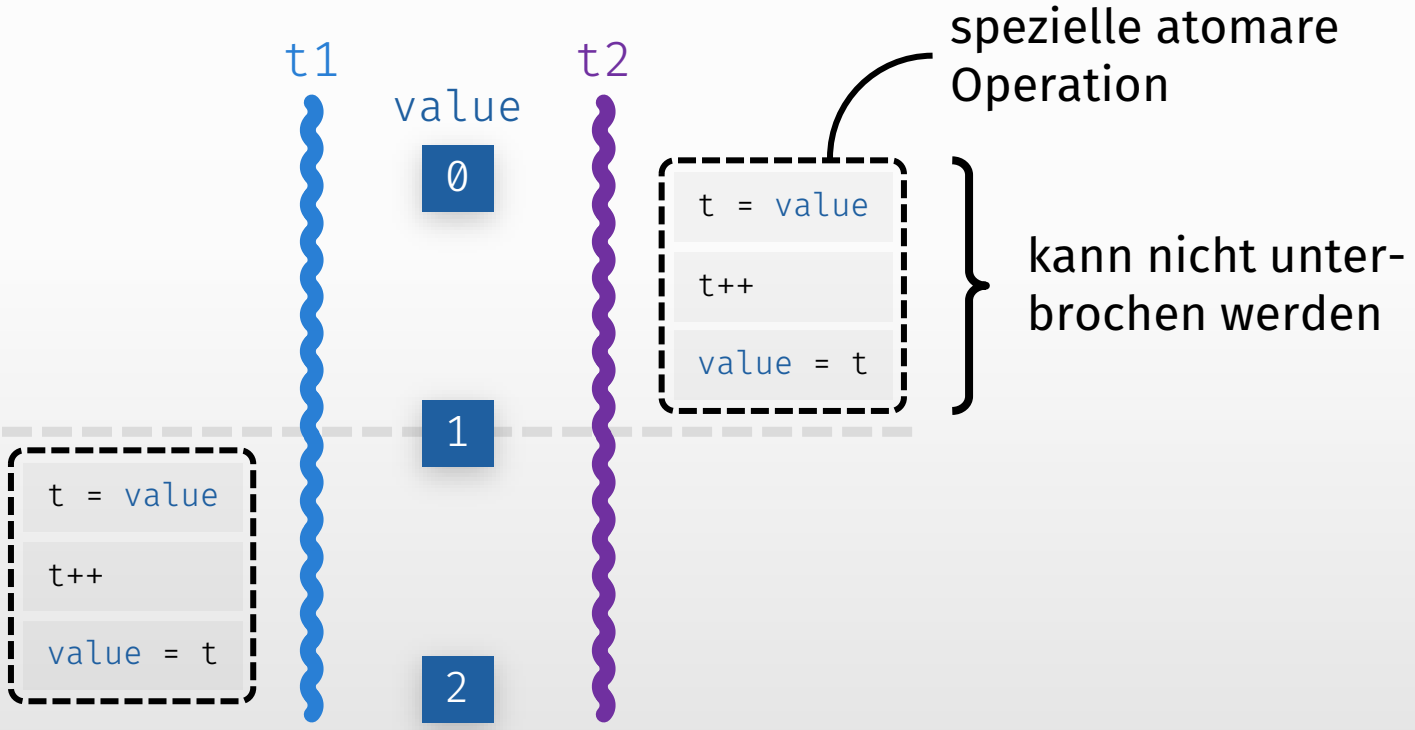

Beispiel: `AtomicInteger`-Klasse aus `java.util.concurrent`

Behälter für einen **int**-Wert

!

```
private final AtomicInteger value =
      new AtomicInteger(0);

private void run() throws InterruptedException {
   Runnable incrementer = () -> {
      for (int i = 0; i < 10000; i++) {
         value.incrementAndGet();
      }
   };

   var first = new Thread(incrementer);
   var second = new Thread(incrementer);
   first.start(); second.start();
   first.join(); second.join();
   System.out.println(value.get());
}
```

atomare Operation

Beobachtetes Verhalten:

```
20000
```

immer, garantiert!

3. Problem: Deadlock

Alternative zu atomarer Operation (und `volatile`): ***Lock***

```
private int value = 0;

private void run() throws InterruptedException {
   Runnable incrementer = () -> {
      for (int i = 0; i < 10000; i++) {
         synchronized (this) {
            value += 1;
         }
      }
   };

   var first = new Thread(incrementer);
   var second = new Thread(incrementer);
   first.start(); second.start();
   first.join(); second.join();
   System.out.println(value);
}
```

Beobachtetes Verhalten:

```
20000
```

Vorteil von Locks: beliebiger Codeblock wird «atomar» ausgeführt

- Immer nur ein Thread kann Code in `synchronized`-Block ausführen, andere warten

Problem: wenn *mehrere Locks* verwendet werden, kann es sein, dass zwei Threads jeweils auf das andere Lock warten → ***Deadlock***

```
synchronized (objektA) {
    synchronized (objektB) {
        ...
    }
}
```

Thread 1

```
synchronized (objektB) {
    synchronized (objektA) {
        ...
    }
}
```

Thread 2

Passiert *sehr selten*, aber wenn es passiert, dann wahrscheinlich zum ungünstigsten Zeitpunkt...