Application Performance Management

Frühling 2023

Garbage Collection

Zoltán Majó

Vorstellung

Berufserfahrung

Seit 2017: Senior Software Engineer / Technical Consultant / Projekt Manager

Ergon Informatik AG, Zürich

2014-2017: Compileringenieur Java Virtuelle Maschine

Oracle Corporation

Studium

2008-2014: Doktorat an der ETH Zürich


2002-2007: Informatikstudium, TU Cluj, Rumänien

Lehre


2017: Vorlesung Kompilerbau an der ETH Zürich

Seit 2018: APM an der FHNW

Aufbau einer typischen Applikation



Unser Fokus



Performanceeinfluss

Einflussfaktoren durch einen Managed Runtime

Garbage Collection	Wird am heutigen APM-Anlass betrachtet
Just-in-Time Kompilierung	Wird im nächsten APM-Anlass betrachtet

- Class Loading
- Optimierungstechnicken f
 ür Managed Runtimes
 - z.B. Inline Caching

•

Basis für praxisnahe Diskussion: Java Hotspot VM

- Konkretes Bespiel eines Managed Runtimes
- Breite Verwendung weltweit
- Prinzipien gelten auch für andere Systeme

Garbage Collection

- Was ist GC?
- Was beeinflusst die Performanz von GC?
 - Komplexität des GC-Algorithmus
 - Implementierung des Algorithms
 - Generational GC
 - Serielle, parallele und nebenläufige GC
- Wie beinflusst GC die Performanz von Applikationen
 - Wichtige Performanzmerkmale
 - Performanzerhöhung durch GC Tuning

Danke an Prof. Dr. Thomas R. Gross (ETH Zürich) für (ein Teil) der Folien

Speicherverwaltung

Viele moderne Programmiersprachen unterstützten dynamische Speicherallokation


Programme können z.B. Records, Arrays und Objekte zur Laufzeit allokieren

Die Programmiersprache muss mit der Zurückforderung und Recycling allokierter Speicher umgehen können

- Teil der Spezifikation der Programmiersprache
- Aufgabe wird dem Runtime System (z.B., der Java Virtuelle Maschine) überlassen

Speicherlayout

Virtueller Speicher (per Prozess)



Speicherplatz

Virtueller Speicher ist unbegrenzt

Zumindest konzeptuell

Physischer Speicher ist begrenzt

- Limite kann vom Betriebssystem gesetzt werden
- Limite kann beim Prozessstart gesetzt werden (aus Rücksicht auf andere Prozesse)
- Der Adressraum ist limitiert

Performanz ist wichtig

Festplatten sind weniger performant als Hauptspeicher

Unbenutzte Daten müssen entfernt werden

→ «Garbage Collection» (GC)

GC

Was ist «Garbage» (dt. Müll)?

• Ein Objekt im Programm ist Müll, wenn das Objekt von keiner Berechnung wieder verwendet wird.

Ist es einfach festzustellen, welche Objekte Müll sind?

• Nein. Es ist unentscheidbar. Zum Beispiel:

```
v = new Object();
if (long-and-tricky-computation) {
   use v
} else {
   don't use v
}
```

GC (Forts.)

Da es schwierig ist festzustellen, welche Objekte Müll sind, verwenden Programmiersprachen unterschiedliche Ansätze um Speicher zu rezyklieren

Ansatz 1: Der Programmierer muss sich darum kümmern

Explizite Allokation/Deallokation

Ansatz 2: Das Laufzeitsystem muss sich darum kümmern

- Automatisch
- Viele Algorithmen stehen zur Verfügung

Ansatz 1: Explizite Speicherverwaltung

Verwaltung des Speichers mittels einer Bibliothek

Programmierer entscheidet wann und wo Speicher alloziert/dealloziert wird

```
void* malloc(long n)
void free(void *addr)
```

Wenn nötig, die Bibliothek beantragt mehr Pages vom Betriebssystem

Mittels Systemcalls

Vorteile/Nachteile der expliziten Speicherverwaltung

Vorteile:

- Programmierer sind schlau
- Programmierer entscheidet, wann der Mehraufwand der Allozierung akzeptabel ist

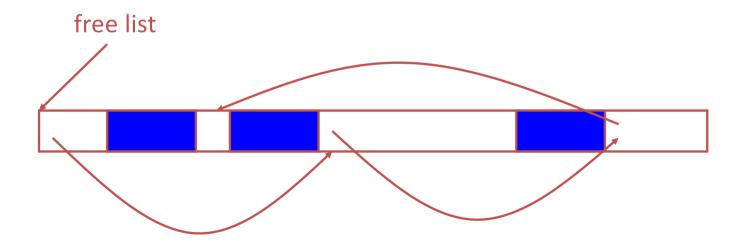
Nachteile:

- Auch schlaue Programmierer machen Fehler
- Programmierer möchten sich nicht unbedingt mit solchen Details beschäftigen
- Automatische Speicherverwaltung kann günstig sein

Explizite Speicherverwaltung: Details

Wie funktioniert malloc/free?

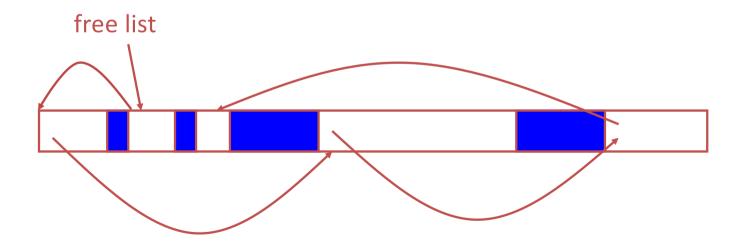
- Nicht (mehr) verwendete Speicherblöcke befinden sich in der "free list"
- malloc: sucht in der free list nach einem genug grossen Speicherblock
- free: plaziert Speicherblock zum Anfang der free list



Explizite Speicherverwaltung: Details

Wie funktioniert malloc/free?

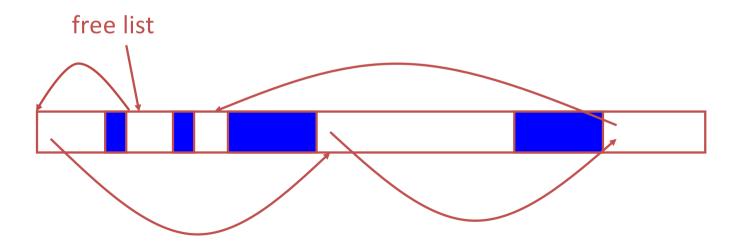
- Nicht (mehr) verwendete Speicherblöcke befinden sich in der "free list"
- malloc: sucht in der free list nach einem genug grossen Speicherblock
- free: plaziert Speicherblock zum Anfang der free list



Explizite Speicherverwaltung: Details

Nachteile

- malloc is nicht für umsonst: Aufwand der Suche nach einem Block, der gross genug ist, kann signifikant sein
- Der Heap wird fragmentiert, während das Programm ausgeführt wird



Mögliche Lösungen

Mehrere free lists

- Eine free list für jede gegebene Blockgrösse
- Malloc und free sind beide O(1)
- Mögliches Problem: Liste mit Blöcken der Grösse 4 ist verbraucht, auch wenn Blöcke der Grösse 2 und 6 verfügbar sind

Blöcke mit Zweierpotenzen-Grössen

- Blöcke werden aufgeteilt um richtige Grösse zu erreichen
- Bei Freigabe werden angrenzende Blöcke zusammengeschmolzen

Fragmentierung in jedem Fall vorhanden

- Verschwendeter Speicherplatz
- «No magic bullet»: Speicherverwaltung kostet immer was

Automatische Speicherverwaltung – wieso?

Programmieren mit expliziter Speicherverwaltung viel schwieriger ist als mit automatischer Speicherverwaltung

- Konstante Sorge wegen «Dangling Pointers»
 - Instabilität, Maintenance
- Es ist schwierig ein sicheres System zu entwickeln
 - Das System gibt keine Garantien
- Programmieren mit Sprachen, die automatische Speicherverwaltung unterstützen, ist einfacher
- Unterliegendes Laufzeitsystem kann den den Speicher immer noch explizit verwalten

Ansatz 2: Automatische Speicherverwaltung

Zentrale Frage:

Wie wird entschieden, welche Objekte Müll sind?

 (Ein Objekt im Programm ist Müll, wenn keine Berechnung im Programm dieses Objekt wieder verwendet.)

Übliche Lösung: Ein Objekt ist Müll, wenn es von den "Roots" aus nicht mehr erreichbar ist

- Roots = Register, Stack, globale statische Daten
 - Falls es vom Root aus zu einem Objekt keinen Pfad gibt, das Objekt kann nicht mehr im Programm verwendet werden und kann daher zurückgefordert werden.
- Zurückhaltende Approximation
 - Engl. «conservative approximation»

Ansatz 2: Automatische Speicherverwaltung (Forts.)

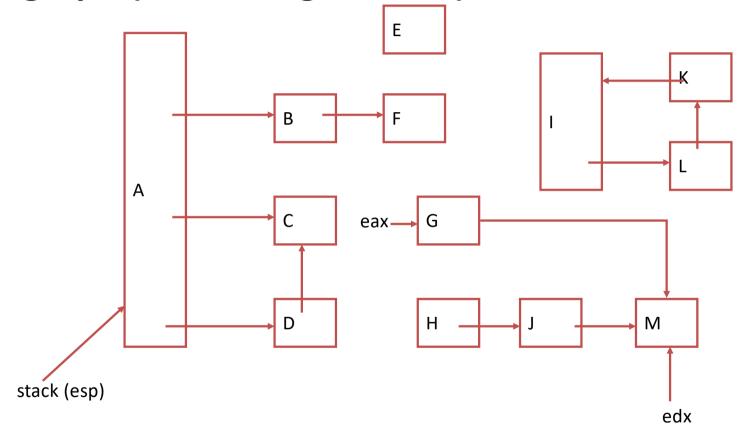
Es gibt verschiedene Ansätze um automatische Speicherverwaltung zu realisieren

Die meisten Differenzen sind bezüglich

- Wie wird entschieden, welche Objekte nicht erreichbar sind
- Wie werden (nicht) erreichbare Objekte behandelt

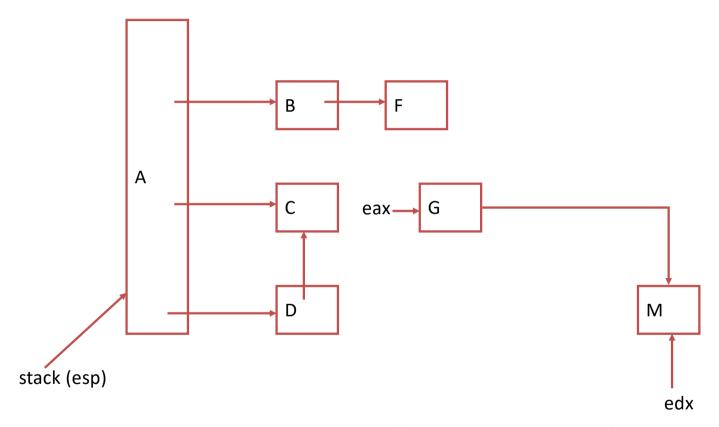
Fokus des heutigen Anlasses: (automatische) Garbage Collection

Objektgraph (eines Programmes)



Welche Objekte sind erreichbar (von den Roots aus)?

Objektgraph (eines Programmes) – nach GC



Welche Objekte sind erreichbar (von den Roots aus)?

Diskussion: Wann kann GC passieren?

Immer

- Jedoch wird GC häufig durch Allokationen ausgelöst
- Siehe Beispiel

```
class Foo {
  public static void main(String args[]) {
    Object v;
    v = new Object();
    System.out.println(v);
    System.gc();
}
```

Diskussion: Wann kann GC passieren?

Immer während des Verlauf des Programmes Jedoch wird GC häufig durch Allokationen ausgelöst Siehe Beispiel class Foo { public static void main(String args[]) { Object v; v = new Object(); Heap vorher System.out.println(v); System.gc(); }

Heute diskutierte Algorithmen

Mark & Sweep GC

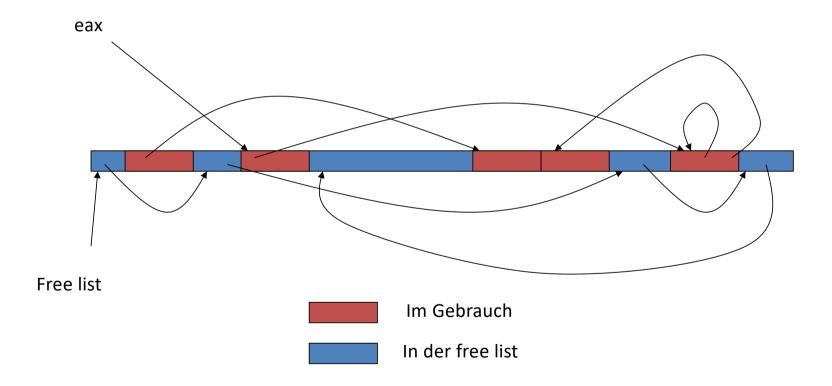
Mark & Copy GC

Mark & Compact GC

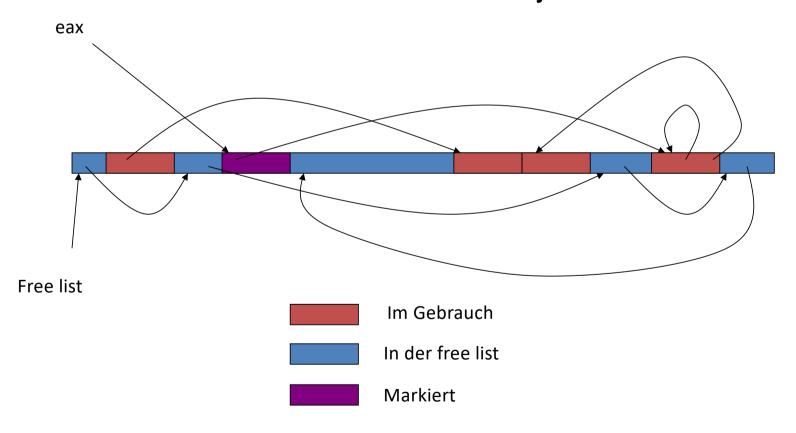
Mark & Sweep GC

Algorithmus besteht aus zwei Phasen

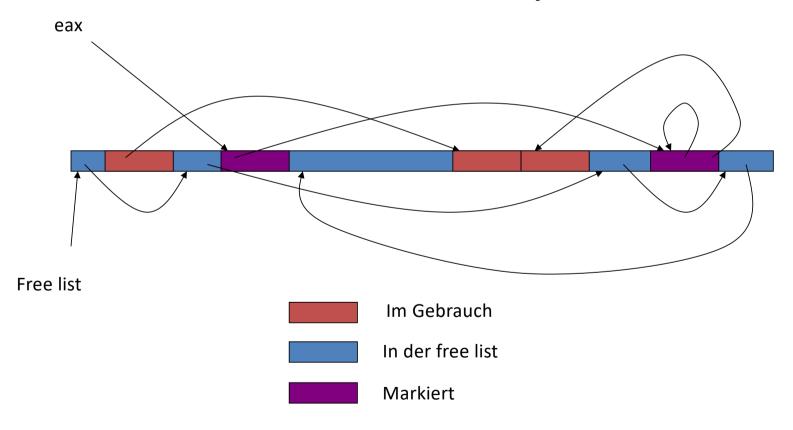
- Mark: Objektgraph wird "depth-first" durchquert und vom Root aus erreichbare Objekte werden markiert
- Sweep: Der ganze Heap wird durchquert, nicht markierte Objekte werden der free list zugefügt, die Markierung aller Objekte wird gelöscht



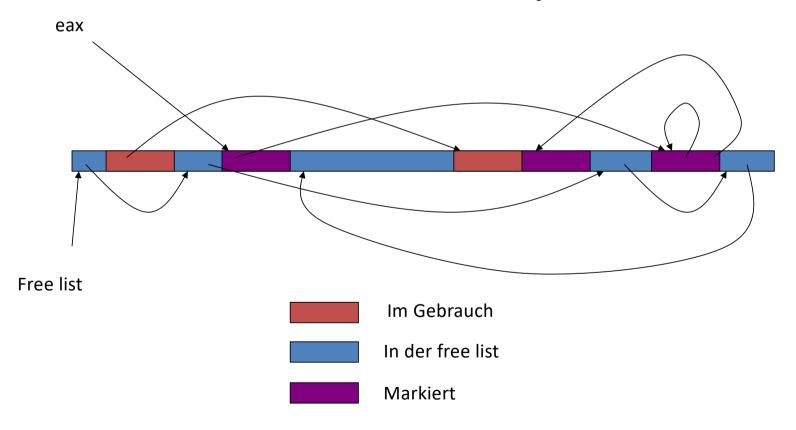
Mark Phase: vom Root aus erreichbare Objekte werden markiert



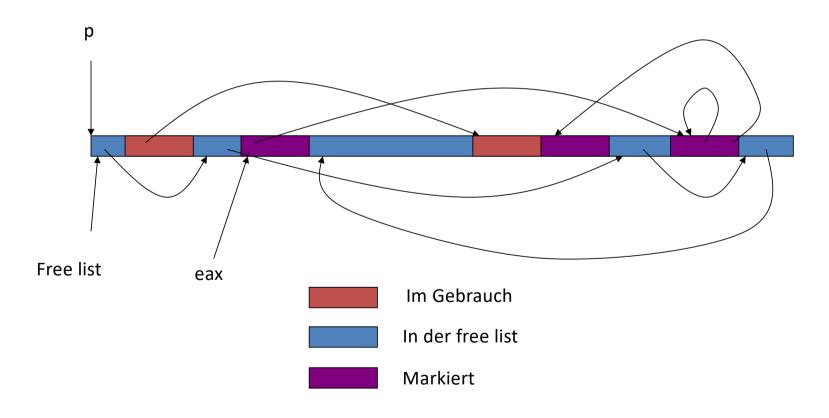
Mark Phase: vom Root aus erreichbare Objekte werden markiert

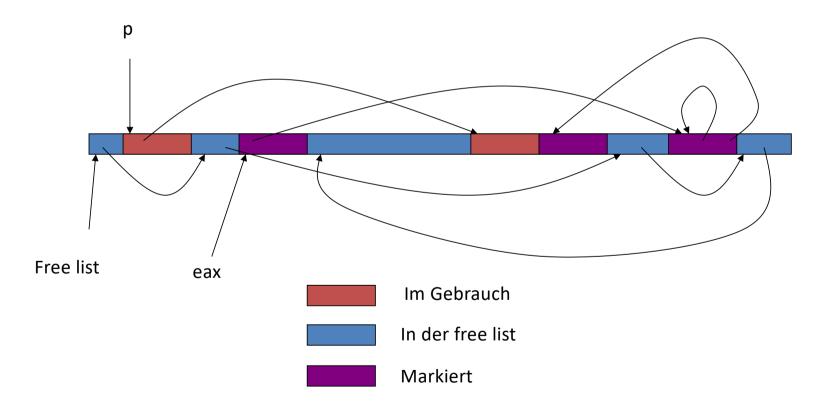


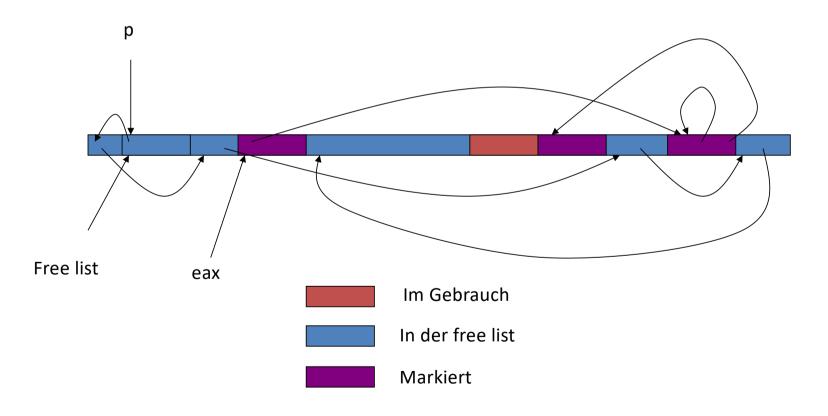
Mark Phase: vom Root aus erreichbare Objekte werden markiert

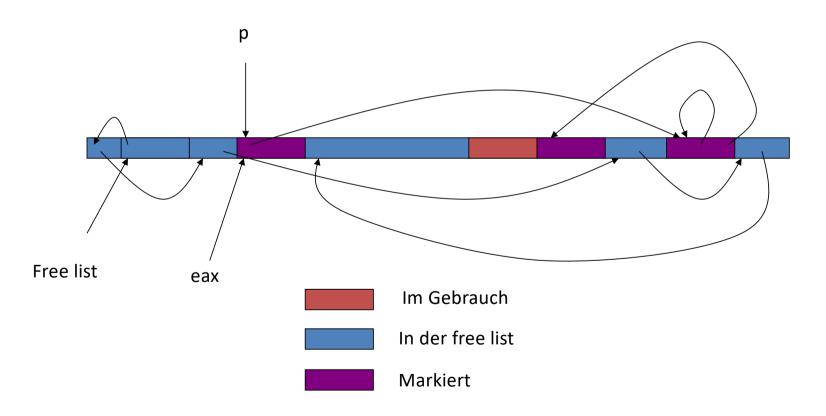


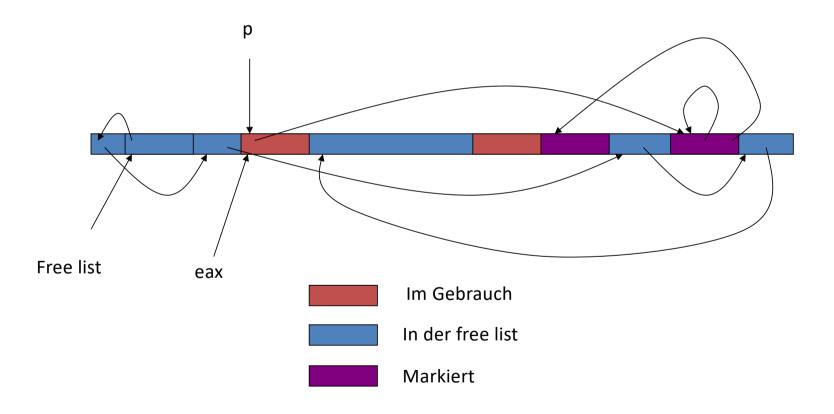
Sweep Phase: Sweep Pointer p aufsetzen; Sweep starten





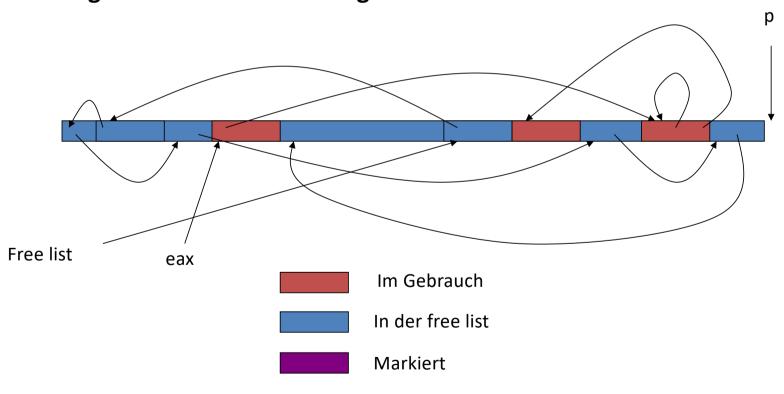






Mark & Sweep: Zeitlupe

Sweep Phase: GC fertig, wenn Ende des Heaps erreicht wird; Ausführung des Programm kann wieder aufgenommen werden



Bemerkungen: Mark & Sweep GC

Vorteile

- GC wird «in situ» durchgeführt
- Kein Extra Speicherplatz nötig

Nachteile

- Fragmentierung kann ein Problem sein
- Programm muss während des GCs gestoppt werden
- Allokierung kann langsam sein: Ein passender Block muss in der free list gesucht werden
- Sweep-Phase muss den ganzen Heap überqueren
 - Algorithmus kann weiter optimiert werden (wird heute nicht diskutiert)

Mark & Copy

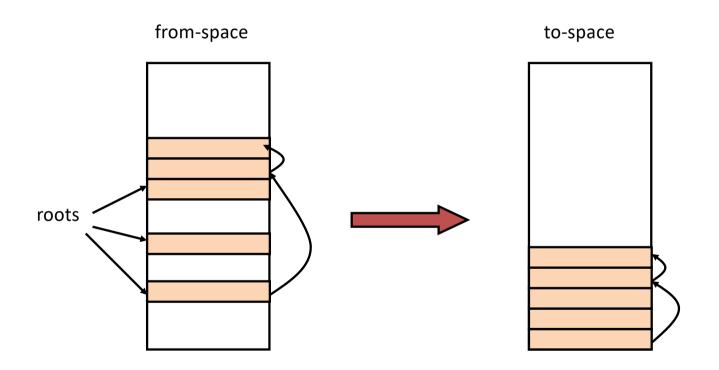
Idee: 2 Heaps werden verwendet

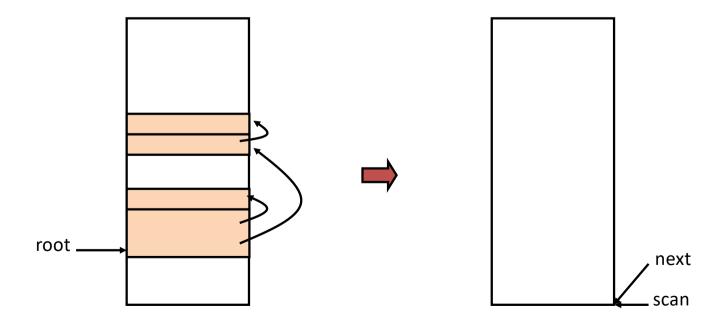
- Ein Heap (sog. from-space) wird vom Programm verwendet
- Der andere Heap (sog. to-space) nicht verwendet bis GC startet

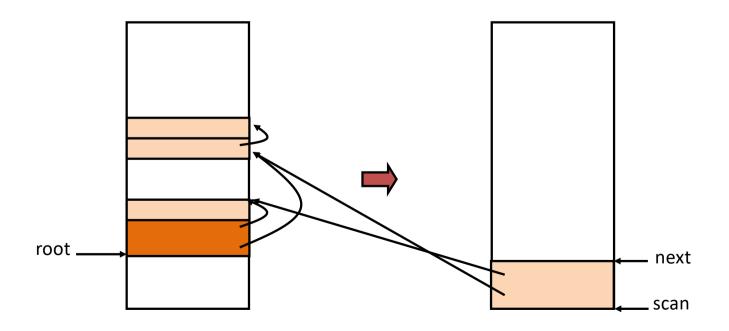
GC:

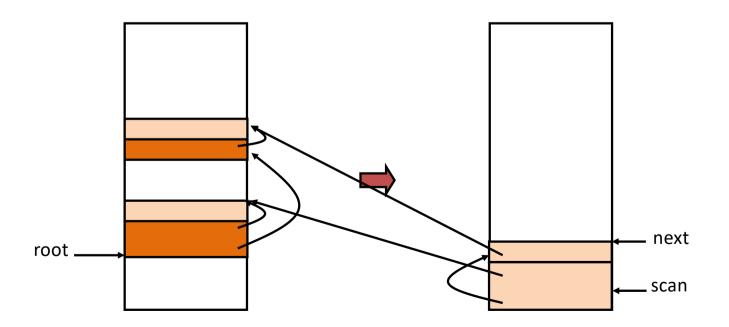
- Startet beim Root Set und traversiert den Objektgraphen
- Erreichbare Objekte werden vom from-space ins to-space kopiert
- Unerreichbare Objekte sind im from-space hinterlassen
- Die Rolle der Heaps wird gewechselt

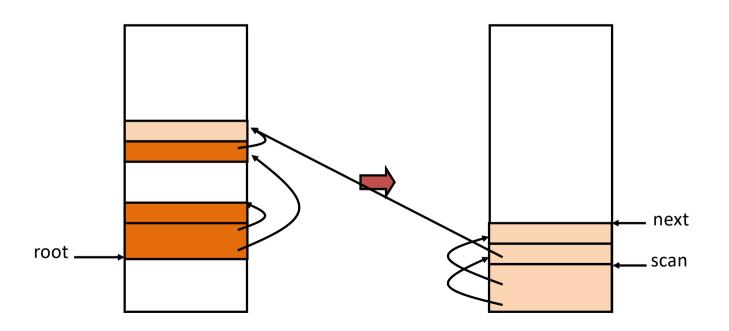
Mark & Copy

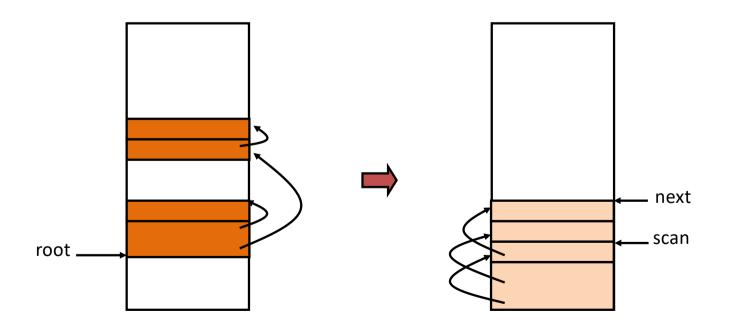


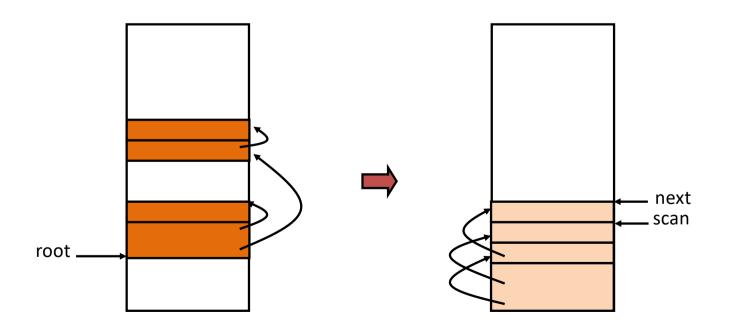


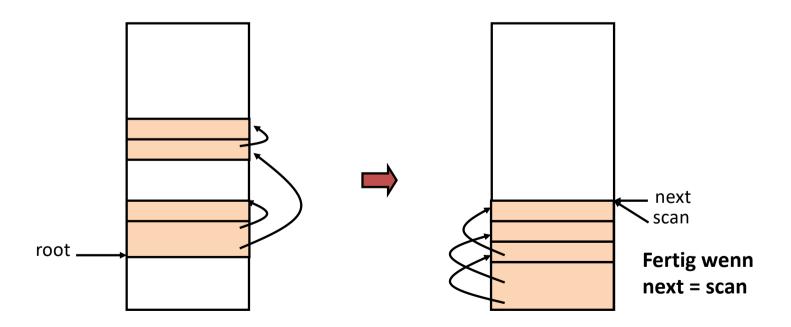


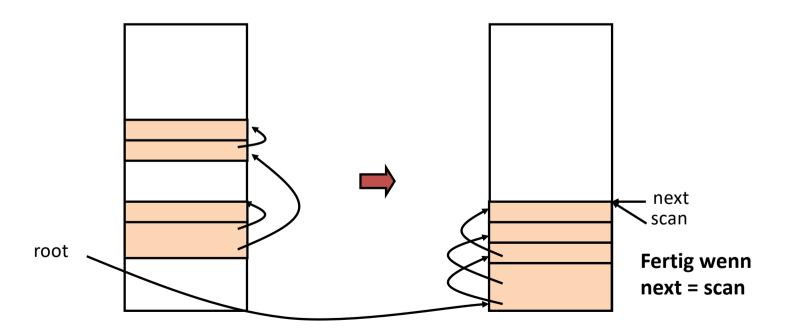












Bemerkungen (Mark & Copy)

Vorteile

- Einfach
- Eliminiert Fragmentierung
- Laufzeit proportional zum Anzahl erreichbaren Objekten
- Schnelle Allozierung: Pointer wird mit Objektgrösse inkrementiert

Nachteile

- Zusätzlicher Speicherplatz nötig
- Programm muss während des GCs gestoppt werden

Mark-Compact GC

Ähnlich wie Mark & Sweep

Unterschied: Nach der Mark Phase werden Objekte zum Anfang des Heaps umgelegt

Vorteile

- Keine Fragmentierung
- In-situ: Kein zweiter Heap nötig

Nachteile

- Zusätzliche Traversierung des Heaps nötig (3 Traversierungen insgesamt)
- Programm muss während des GCs gestoppt werden

Diskussion:

Vergleich Speicherverwaltungsmethoden Relevante Kriterien?

Algorithmus		
Mark & Sweep GC		
Mark & Copy GC		
Mark & Compact GC		

Diskussion: Vergleich Speicherverwaltungsmethoden

Algorithm us	Fragmentierung	Footprint	Stop-the-world	Geschwindigkeit Allozierung	Geschwindigkeit GC
Mark & Sweep GC	×	V	×	×	×
Mark & Copy GC		×	×		
Mark & Compact GC		✓	×		×

Diskussion:

Vergleich Speicherverwaltungsmethoden

Bemerkung: Alle Algorithmen müssen die Applikation stoppen

Algorithm us	Fragmentierung	Footprint	Stop-the-world	Geschwindigkeit Allozierung	Geschwindigkeit GC
Mark & Sweep GC	×	V	×	×	×
Mark & Copy GC		×	×		
Mark & Compact GC		~	×		×

Bemerkungen

Kein Algorithmus hat ein gutes Resultat bei allen Kriterien

Stop-the-world ist problematisch bei allen

Frage: Könnte man verschiedene Algorithmen kombinieren?

■ «Best-of-both-worlds» Lösung → Generational GC

Garbage Collection

- Was ist GC?
- Was beeinflusst die Performanz von GC?
 - Komplexität des GC-Algorithmus
 - Implementierung des Algorithms
 - Generational GC
 - Serielle, parallele und nebenläufige GC
- Wie beinflusst GC die Performanz von Applikationen
 - Wichtige Performanzmerkmale
 - Performanzerhöhung durch GC Tuning

Generational GC

Empirische Beobachtung 1

Wenn ein Objekt eine lange Zeit erreichbar war, wird es wahrscheinlich erreichbar bleiben

Empirische Beobachtung 2

In vielen Programmen sterben die meisten Objekte jung

Idee 1: Arbeit wird erspart, wenn junge Objekte häufig und alte Objekte selten gescanned werden.

Idee 2: Alten Objekten kann mehr Aufwand gewidmet werden.

Generational GC in der HotSpot JVM


Bemerkung: Bisher wurde GC unabhängig von einer konkreten Implementierung betrachtet

Ab jetzt diskutieren wir eine konkrete Implementierung (Java HotSpot 8)

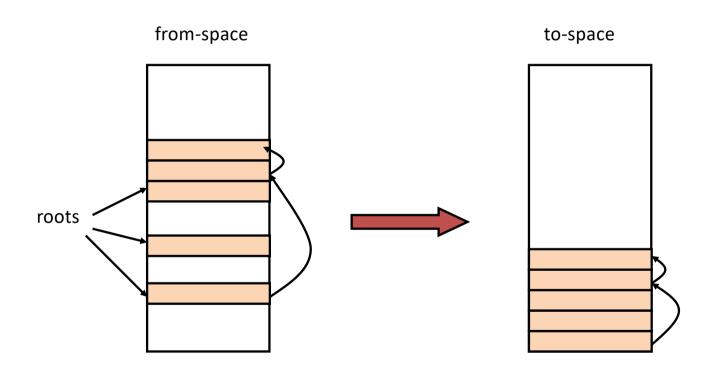
Generational GC in der HotSpot JVM

Welche Objekte darf der Minor GC nicht vergessen?

Heap Layout




Hint: Mark & Copy (wie vorhin gezeigt)




Generational GC in der HotSpot JVM

Heap Layout




Generational GC in der HotSpot JVM

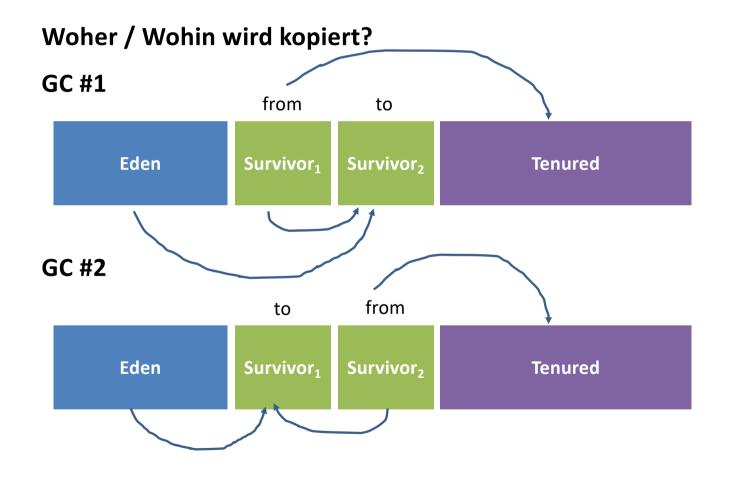
Heap Layout



Minor GC



Minor GC



Verbesserung Performanz

Was sind aus Applikationssicht wichtige Performanzmerkmale?

- Durchsatz
- Reaktionsfähigkeit

Ansätze

Für Steigerung des Durchsatzes: Paralleler GC

GC Algorithmus parallelisiert

Für Reduzierung der Pausenzeiten: Nebenläufiger GC

• GC Algorithmus (oder Teile davon) läuft gleichzeitig mit dem Benutzerprogramm

Annahmen für Beispiel

Applikation

- Parallel mit zwei Threads
- Perfekt parallelisiert

Hardware

Zwei Prozessorkernen

Serieller vs. Paralleler vs. Nebenläufiger GC

Serieller GC	Applikation GC Applikation GC
Paralleler GC	Applikation GC Applikation GC
Nebenläufiger GC	Applikation GC Applikation GC
	Zeit

Fragen

Bei welcher GC-Variante ist der Durchsatz der Applikation am besten?

Bei welcher GC-Variante sind die Pausenzeiten der Applikation am niedrigsten?

HotSpot GCs: Übersicht

Serial GC

- Young Generation: Serieller Mark & Copy
- Old Generation: Serieller Mark & Compact

Parallel GC

- Young Generation: Paralleler Mark & Copy
- Old Generation: Paralleler Mark & Compact

Nebenläufiger GC: Concurrent Mark and Sweep (CMS)

- Young Generation: Paralleler Mark & Copy
- Old Generation: Mostly Concurrent Mark & Sweep

GC Tuning

Wiederholung: Was sind aus Applikationssicht wichtige Performanzmerkmale?


- Durchsatz
- Reaktionsfähigkeit

Auch wenn der für das Ziel entsprechende GC-Implementierung eingeschaltet wurde, ist die Performanz manchmal nicht gut genug

Problem kann manchmal durch einen manuellen Eingriff gelöst werden = GC Tuning

GC Tuning

Setup




Beispieloutput

■ava HotSpot(TM) 64-Bit Server VM (25.141-b15) for bsd-amd64 JRE (1.8.0_141-b15), built on Jul 12 2017 04:35:23 by "java_re" with gcc 4.2.1 (Based on Apple Inc. build 5658) (LLVM build 2336.11.00)
Memory: 4k page, physical 16777216k(1248276k free)

/proc/meminfo:

CommandLine flags: -XX:InitialHeapSize=33554432 -XX:MaxHeapSize=33554432 -XX:MaxHeapSize=33554432 -XX:NewRatio=1 -XX:+UseCompressedCops -XX:+UsePa 0.120: [GC (Allocation Failure) [PSYoungGen: 6143K->5106K(11264K)] 6143K->5794K(27648K), 0.0030349 secs] [Times: user=0.01 sys=0.01, real=0.00 secs] 0.167: [GC (Allocation Failure) [PSYoungGen: 11239K->3729K(11264K)] 11927K->4425K(27648K), 0.0032820 secs] [Times: user=0.00 sys=0.01, real=0.00 secs] 0.171: [GC (Allocation Failure) [PSYoungGen: 9865K->1648K(11264K)] 10561K->2344K(27648K), 0.0006056 secs] [Times: user=0.01 sys=0.00, real=0.00 secs] 0.172: [GC (Allocation Failure) [PSYoungGen: 7786K->5090K(11264K)] 8482K->8475K(27648K), 0.0022283 secs] [Times: user=0.00 sys=0.01, real=0.00 secs] 0.218: [GC (Allocation Failure) [PSYoungGen: 11229K->5106K(11264K)] 14615K->9020K(27648K), 0.0012928 secs] [Times: user=0.01 sys=0.01, real=0.00 secs] 0.267: [GC (Allocation Failure) [PSYoungGen: 11246K->3553K(11264K)] 15160K->7467K(27648K), 0.0011604 secs] [Times: user=0.00 sys=0.00, real=0.00 secs] 0.270: [GC (Allocation Failure) [PSYoungGen: 9693K->1152K(11264K)] 13607K->5346K(27648K), 0.0009220 secs] [Times: user=0.01 sys=0.00, real=0.00 secs] 0.272: [GC (Allocation Failure) [PSYoungGen: 7293K->5090K(11264K)] 11487K->11469K(27648K), 0.0019212 secs] [Times: user=0.00 sys=0.00, real=0.00 secs] 0.316: [GC (Allocation Failure) [PSYoungGen: 11231K->5090K(11264K)] 17610K->11621K(27648K), 0.0013460 secs] [Times: user=0.01 sys=0.00, real=0.00 secs] 0.370: [GC (Allocation Failure) [PSYoungGen: 11216K->2080K(11264K)] 17747K->8628K(27648K), 0.0006940 secs] [Times: user=0.00 sys=0.00, real=0.00 secs] 0.372: [GC (Allocation Failure) [PSYoungGen: 8222K->5090K(11264K)] 14769K->14671K(27648K), 0.0026775 secs] [Times: user=0.01 sys=0.01, real=0.00 secs] 0.375: [GC (Allocation Failure) [PSYoungGen: 11231K->5090K(11264K)] 20812K->15663K(27648K), 0.0014235 secs] [Times: user=0.01 sys=0.01, real=0.00 secs] 0.419: [GC (Allocation Failure) [PSYoungGen: 11231K->4001K(11264K)] 21804K->14590K(27648K), 0.0009612 secs] [Times: user=0.00 sys=0.00, real=0.00 secs] 0.467: [GC (Allocation Failure) [PSYoungGen: 10143K->1920K(11264K)] 20732K->12525K(27648K), 0.0006870 secs] [Times: user=0.00 sys=0.00, real=0.00 secs] 0.468: [GC (Allocation Failure) [PSYoungGen: 8062K->5090K(11264K)] 18667K->18592K(27648K), 0.0026388 secs] [Times: user=0.00 sys=0.01, real=0.00 secs] 0.471: [Full GC (Ergonomics) [PSYoungGen: 5090K->0K(11264K)] [ParOldGen: 13502K->8264K(16384K)] 18592K->8264K(27648K), [Metaspace: 2682K->2682K(1056768K)], 0.0040828 secs] [Times: user=0.02 sys=0.00, real=0.01 secs]



Übung

1. Testprogramm kompilieren: javac Test.java

Heute nutzen wir Java 8


2. Testprogramm mit reduzierter Heapgrösse ausführen

- java -Xmx64M -verbose:gc -XX:+PrintGCDetails -Xloggc:gc-64m-default.log.txt Test
- Frage 1: Was ist der Durchsatz und die maximale Pausenlänge bei dieser Ausführung?

3. Testprogramm mit Custom-Flags ausführen

- java -Xmx64M -verbose:gc -XX:+PrintGCDetails -XX:NewRatio=1 -XX:SurvivorRatio=8 -Xloggc:gc-64m-NR1-SR8.log.txt Test
- Frage 2: Was bewirken die Flags NewRatio und SurvivorRatio? Hint: JSGCT.pdf
- Frage 3: Was ist der Durchsatz und die maximale Pausenlänge bei dieser Ausführung?
- Frage 4: Ist es durch die Verwendung der Flags -XX:GCTimeRatio und -XX:MaxGCPauseMillis einen höheren Durchsatz bzw. niedrigere maximale Pausenzeit als bei Frage 2 und 3 zu erreichen?

Frage 1: Was ist der Durchsatz und die maximale Pausenlänge bei der Ausführung -Xmx64M?



Frage 2: Was bewirken die Flags NewRatio und SurvivorRatio?


-Xmx64M



-Xmx64M -XX:NewRatio=1 -XX:SurvivorRatio=8



Frage 3: Was ist der Durchsatz und die maximale Pausenlänge der Ausführung mit -XX:NewRatio=1 -XX:SurvivorRatio=8 ?



Diskussion

Ist GC Tuning einfach oder eher schwierig? (Denken Sie auch an echte Applikationen) Wieso?

Kommandozeilen – Beispiele

```
java -Xmx12g -XX:MaxPermSize=64M -XX:PermSize=32M -XX:MaxNewSize=2g
-XX:NewSize=1g -XX:SurvivorRatio=128 -XX:+UseParNewGC
-XX:+UseConcMarkSweepGC -XX:MaxTenuringThreshold=0
-XX:CMSInitiatingOccupancyFraction=60 -XX:+CMSParallelRemarkEnabled
-XX:+UseCMSInitiatingOccupancyOnly -XX:ParallelGCThreads=12
-XX:LargePageSizeInBytes=256m ...
java -Xms8g -Xmx8g -Xmn2g -XX:PermSize=64M -XX:MaxPermSize=256M
-XX:-OmitStackTraceInFastThrow -XX:SurvivorRatio=2 -XX:-UseAdaptiveSizePolicy
-XX:+UseConcMarkSweepGC -XX:+CMSConcurrentMTEnabled
-XX:+CMSParallelRemarkEnabled -XX:+CMSParallelSurvivorRemarkEnabled
-XX:CMSMaxAbortablePrecleanTime=10000 -XX:+UseCMSInitiatingOccupancyOnly
-XX:CMSInitiatingOccupancyFraction=63 -XX:+UseParNewGC -Xnoclassgc ...
```

Flags

java -XX:+PrintFlagsFinal | grep "GC\|CMS\|G1" 169

```
uintx AdaptiveSizeMajorGCDecayTimeScale
                                             = 10
                                                                                  {product}
uintx AutoGCSelectPauseMillis
                                             = 5000
                                                                                  {product}
bool BindGCTaskThreadsToCPUs
                                             = false
                                                                                  {product}
bool CMSAbortSemantics
                                             = false
                                                                                  {product}
uintx CMSAbortablePrecleanMinWorkPerIteration = 100
                                                                                  {product}
intx CMSAbortablePrecleanWaitMillis = 100
                                                                                  {manageable}
                                             = 10485760
uintx CMSBitMapYieldQuantum
                                                                                  {product}
uintx CMSBootstrapOccupancy
                                             = 50
                                                                                  {product}
```

Frage

Können wir Applikationseingeschaften festhalten um GC zu lenken?

- Rate der Allozierungen (engl. allocation rate)
- Rate der Mutationen (engl. mutation rate)
- •

Ohne messbare Applikationseigenschaften: Experimentieren

If the heap grows to its maximum size and the throughput goal isn't being met, then the maximum heap size is too small for the throughput goal. Set the maximum heap size to a value that's close to the total physical memory on the platform, but doesn't cause swapping of the application. Execute the application again. If the throughput goal still isn't met, then the goal for the application time is too high for the available memory on the platform.

JSGCT.pdf (HotSpot Virtual Machine Garbage Collection Tuning Guide)

Praxis

Manchmal muss man mit den zur Verfügung stehenden Werkzeugen was machen...

Empfehlung(en) für Tuning

- Sinnvolle und systematische Experimente
- Genug Zeit einplanen
- •

Limiten der GC-Algorithmen gelten

Stop-the-world kann bei allen in GC-Implementierungen in der Oracle JVM vorkommen

Good news

Es gibt neue(re) GC-Implementierungen für Java

Diese benötigen weniger Konfiguration / Tuning

Beispiele

- Garbage-First GC (G1GC) Standardeinstellung seit Java 9
- Azul Zing VM C4 Verfügbar nur in Azul Java VM
- Oracle JVM ZGC Generell verfügbar seit Java 15
- Oracle JVM Shenandoah GC ultra-low pause time garbage collector

G1GC

"[G1GC] attempts to meet garbage collection pause-time goals with high probability while achieving high throughput with little need for configuration."

Heap Layout: Regionen-basiert

Grau: Freie Region

Rot ohne S: Eden

Rot mit S: Survivor

Hellblau: Old Generation

Hellblau mit H: Humongous Objects

Objekte mit einer Grösse > Regionsgrösse / 2 sind humongous

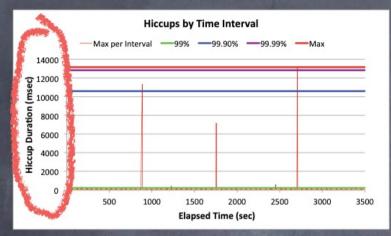
Werden speziell behandelt und sind daher häufige Quelle von Performanzproblemen

Quelle: https://docs.oracle.com/en/java/javase/19/gctuning/


Azul C4


Die folgende Folie ist von Gil Tene (Azul) übernommen worden


Oracle HotSpot CMS, 1GB in an 8GB heap



Zing 5, 1GB in an 8GB heap









The complete guide to Zing GC tuning

java -Xmx40g



Oracle ZGC

Empfohlene Bibliographie

- Gute Zusammenfassung: https://www.youtube.com/watch?v=88E86quLmQA (39 Minuten)
- Details: https://wiki.openjdk.java.net/display/zgc/Main

Zusammenfassung der Vorlesung

Was ist GC?

Was beeinflusst die Performanz von GC?

- Komplexität des GC-Algorithmus
- Implementierung des Algorithmus
 - Generational GC
 - Serielle, parallele und nebenläufige GC

Wie beinflusst GC die Performanz von Applikationen

- Wichtige Performanzmerkmale (aus Sicht Applikation)
- Performanzerhöhung durch GC Tuning
- Ausblick